다중 시기 항공영상의 동적 차량 제거를 위한 텍스처 베이킹
쉬운 장면, 고점유 장면 및 개선 기준선의 통합 보고서

실험 기록 통합본

실험: 2026 년 10 월 25–26 일 문서 작성: 2026 년 10 월 26 일

Abstract

동일 위치의 다중 시기 사진을 하나의 텍스처로 베이킹할 때 차량 관측을 제외하는 가중치 S 의 효과를 조사했다. Block-NeRF 형 의미 마스크, NeRF-HuGS 형 일관성 마스크, RobustNeRF 형 잔차 가중치를 동일한 평면 베이킹에 적용했다. 빈 배경이 다수인 쉬운 장면에서는 미적용 L2 와 시간 중앙값도 강한 결과를 보였으나, 차량이 다수 시기에 관측되는 두 장면에서는 잔차 선택의 실패와 관측 부족이 드러났다. 이에 UV 좌표에서 비차량 관측만 합성하고 미관측 영역을 공간 보간하는 기준선 및 마스크 투영 · 초기화 · 공간 정규화 변형을 비교했다. 그림자 후보 제외를 추가한 직접 UV 합성은 고점유 차량 위치 PSNR 에서 B 21.00dB, C 22.23dB 를 얻었으며, 기존 Block 형 대비 각각 약 1.06dB, 1.25dB 높았다. 추가로 같은 관측 선택을 유지한 gradient-domain 조화와 패치 전사를 비교했으며 지표 · 장면에 따라 개선과 악화가 함께 나타났다. 결과는 실제 정사사진을 사용하는 반합성 평면 실험에 한정된다. 미관측 배경의 보간과 어두운 잔상이 남아 완전한 차량 제거를 뜻하지 않는다.

Contents

1 Intro **3**
1.1 문제와 연구 질문 . . . 3
1.2 범위와 용어 . . . 3

2 Method **3**
2.1 영상 출처, 장면과 전처리 . . . 3
2.2 공통 틀: 같은 L2 오차에 어떤 관측 가중치 S 를 곱하는가? . . . 4
2.3 L2 / no-removal: 모든 관측을 사용 . . . 4
2.4 Block 형: 차량 클래스이면 관측을 제외 . . . 5
2.5 HuGS 형: 정적으로 일관된 영역만 사용 . . . 5
2.6 Robust 형: 현재 잔차로 S 를 반복 갱신 . . . 5
2.7 개선한 S: 원본 마스크를 공통 UV 에서 투영 . . . 6
2.8 관측 선택을 공유하는 직접 UV 합성과 추가 prior . . . 6
2.9 추가 두 방법: 같은 S 를 유지하고 채우는 방식을 개선 . . . 6
2.10 공통 구현: S 이외의 조건 . . . 7
2.11 평가 지표와 실험 간 차이 . . . 7

3 Result **9**
3.1 Easy: 빈 배경 관측이 다수인 장면 . . . 9
3.2 Hard: 높은 차량 점유에서의 기존 기준선 . . . 10

3.3 Improved: 배경 관측 선택과 명시적 공간 prior 12
3.4 추가 실험: 부자연스러운 채움을 줄이는 두 재구성 방법 14
3.5 관측 선택의 시각화: 빨간색은 제외한 관측 S=0 18
3.6 해석, 한계 및 재현 범위 20
3.7 산출물과 실행 기록 20

A 구현 세부 수식 **21**
A.1 표기와 공통 베이킹 모델 21
A.2 공통 최적화 절차 21
A.3 미적용 기준선: L2 와 시간 중앙값 21
A.4 Block-NeRF 형: 의미 클래스에 따른 관측 제외 22
A.5 NeRF-HuGS 형: 특징점 지지, 잔차와 SAM 영역 22
A.6 RobustNeRF 형: 잔차 기반 IRLS 와 공간 문맥 23
A.7 개선 기준선 I: UV 에서 비차량 관측만 합성 23
A.8 개선 기준선 II: 차량 주변의 어두운 후보 제외 24
A.9 개선 기준선 III: 마스크 투영 · 초기화 · 공간 prior 24

1 Intro

1.1 문제와 연구 질문

서로 다른 시기에 촬영한 영상 I_i 를 한 장의 텍스처 T 로 모으면 차량 색도 배경에 섞인다. 본 실험은 메쉬 M 과 카메라 π_i 를 고정하고 관측 가중치 S_i 를 바꿨을 때, 차량 잔상 억제와 지면 디테일 보존이 어떻게 달라지는지를 묻는다. 학습 대상은 NeRF 방사장 전체가 아니라 지면 텍스처 및 시점별 색보정이다.

세 단계의 실험은 다음 논리로 연결된다.

1. **Easy:** 여러 해에 지면이 비고 특정 해에 차량이 많은 장면에서 공통 베이킹과 기존 S 를 검증한다.
2. **Hard:** Easy 에서 L2 도 잘 나온 원인이 빈 관측의 다수 여부인지 확인하기 위해, 차량이 5 회 중 3–4 회 나타나는 두 실제 장면을 추가한다.
3. **Improved:** Hard 에서의 실패를 바탕으로, 소수의 비차량 관측을 직접 합성하고 관측 부족에 공간 사전정보를 넣는 개선 기준선을 비교한다.

1.2 범위와 용어

Block-NeRF, NeRF-HuGS, RobustNeRF 는 관측 선택의 아이디어를 제공한다 [2, 3, 4]. 이하 "형"이라는 표현은 본 실험의 베이킹용 구현을 가리키며 원 논문의 전체 NeRF 학습 재현을 뜻하지 않는다. 제거는 차량 메쉬를 삭제하는 것이 아니라 차량이 찍힌 영상의 색을 텍스처 학습에서 제외하는 것이다. 주차된 정지 차량도 의미 마스크에서는 제거 대상이다.

Easy 문서의 과거 "차량 내부" 는 자동차 실내가 아니다. 실제로는 차체 위치에 둔 반경 5 텍셀 원형 표본이었다. 본 보고서는 이를 **차량 위치 표본**으로 부르고, Hard 에서는 차량 전체 OBB 영역 평가와 명확히 구분한다.

2 Method

2.1 영상 출처, 장면과 전처리

원본은 PDOK 가 제공하는 Beeldmateriaal Nederland 의 연도별 항공 정사영상이다. 서비스는 https://service.pdok.nl/hwh/luchtfotorgb/wms/v1_0이며, Google Maps 캡처나 논문 제공 장면을 사용하지 않았다. 출처 표기는 Beeldmateriaal Nederland / PDOK, CC BY 4.0 이다. 제공처 안내는 참고자료에 기재했다. 영상은 다운로드 후 정합、색 정규화、투영、베이킹으로 가공했다.

WMS 1.3.0 GetMap 으로 같은 장면의 같은 bbox 를 요청하고 레이어를 `2021_orthoHR` 부터 `2026_orthoHR` 까지 바꿨다. 요청은 EPSG:4326, 1500 × 1500px, 약 120 × 120m 다. 약 8cm/px 는 요청 격자 간격으로 실제 촬영 해상도와 구별해야 한다. PNG 를 요청했으나 기록된 응답의 실제 인코딩은 JPEG 다. 연도는 레이어 이름이며 정확한 비행일은 확인하지 않았다.

Table 1: 최종 사용한 실제 장면. 차량 점유는 검출 기반 대리 지표다.

장면	중심 위도	중심 경도	학습 데이터 특성
Easy	52.08235	5.10090	Jaarbeurs 남쪽 주차장, 차량 관측 대부분 1/5
Hard B	52.07400	5.04600	차량 경험 픽셀 중 3 회 이상 점유 68.1%
Hard C	52.07730	5.04895	차량 경험 픽셀 중 3 회 이상 점유 63.0%

최초 Jaarbeurs 후보 (52.08718, 5.10243) 는 공사로 변해 제외했다. 최종 Easy 의 학습 ROI 차량 검

출 수는 2021–2025 년에 $3,0,0,0,223$ 이었다. 그중 차량 검출 경험 픽셀의 99.1% 는 한 해만 점유했다. B 의 학습 차량 마스크 면적은 약 49–59%, C 는 약 46–55% 였다.

Easy 는 SIFT 와 RANSAC 유사변환으로 2023 년 기준 정합을 수행했다. 반복 차량 패턴이 많은 Hard 에서는 잘못된 전역 매칭을 피하기 위해 지리 좌표의 초기 정렬을 이용한 CLAHE 、 LK 전후방 추적과 제한된 변위, RANSAC 유사변환을 사용했다. Hard 의 정합 inlier 중앙 오차는 B 약 0.41–0.97px, C 약 0.34–0.75px 였지만 일부 연도의 inlier 가 적어 전역 정확도를 보장하지 않는다. 지면의 강건한 채널별 gain/bias 로 노출을 정규화했다. 모든 방법은 같은 전처리 결과를 사용한다.

학습은 2021–2025 년, 시간 hold-out 은 2026 년이다. 2026 은 전처리를 거치지만 텍스처 초기화 · 관측 선택 학습 · 최적화 손실에는 사용하지 않는다. Easy 의 `2026_quickorthoHR` 는 별도로 받았으나 독립 촬영 여부가 불명확해 제외했다. 합성 사선 카메라 4 장은 동일 연도 사진의 재투영으로, 독립 촬영 4 회가 아니다.

2.2 공통 틀: 같은 L2 오차에 어떤 관측 가중치 S 를 곱하는가?

모든 학습형 비교의 출발점은 하나다. 텍스처를 렌더한 색과 입력 사진의 색을 비교하고, **사용할 관측에는 $S=1$, 제외할 관측에는 $S=0$** 을 곱한다.

$$\min_{T} \mathcal{L}_{\text{bake}}(T) = \sum_{i} \sum_{r \in \Omega_i} \underbrace{S_i(r)}_{\text{이 관측을 쓸 것인가?}} \underbrace{\left\| \widehat{I}_i(T;r) - I_i(r) \right\|_2^2}_{\text{공통 L2 색 오차}} \tag{1}$$

I_i 는 입력 영상, $\widehat{I}_i(T;r)$ 는 텍스처 T 를 카메라 i 에서 렌더한 예측 색, Ω_i 는 유효한 지면 픽셀 집합이다. 여기서 L2 는 RGB 차이의 **제곱합**이다. **핵심 비교는 오차 함수를 바꾸는 것이 아니라 S_i 를 어떻게 만드는지를 바꾸는 것**이다.

식(1)은 공통 구조를 보여주는 식이다. 실제 구현은 RGB3 채널 평균과 batch 의 valid 픽셀 수로 정규화하고 시점별 색보정 정규화를 더한다. S 로 제외한 픽셀 수에 따라 분모를 다시 줄이지 않는다. 공통 색보정과 정확한 정규화는 부록에 분리했다.

Table 2: 공통 $S\times$L2 틀에서 본 기준선의 차이.

방법	$S=1$ 로 남기는 관측의 기준	갱신
L2 / no-removal	모든 valid 관측	항상 1
Block 형	차량 클래스로 검출되지 않은 픽셀	학습 전 고정
HuGS 형	특징점 · 잔차 · SAM 으로 고른 정적 영역	학습 전 고정
Robust 형	현재 잔차가 작고 주변도 inlier 인 영역	매 반복
Geometry mask	원본 UV 마스크를 투영한 비차량 영역	학습 전 고정

차량 관측의 S 를 0 으로 해도 같은 위치에 빈 지면 관측이 남아 있어야 배경색을 얻을 수 있다. 어떤 해에도 배경이 보이지 않았다면 S 만 바꿔서는 원래 지면을 알아낼 수 없다.

2.3 L2 / no-removal: 모든 관측을 사용

$$S_i^{\text{L2}}(r) = 1. \tag{2}$$

차량 여부를 판단하지 않고 모든 유효 관측의 L2 오차를 줄인다. 같은 위치에 빈 배경이 많이 보이면 차량색이 희석되지만, 차량이 다수 시기에 보이면 그 색이 텍스처에 남는다. 이 기준선은 별도의 제거 기법을 적용하지 않은 베이킹이다.

2.4 Block 형: 차량 클래스이면 관측을 제외

검출 마스크 $D_i(r)$ 를 차량이면 1, 아니면 0 으로 정의한다.

$$\boxed{S_i^{\text{Block}}(r) = 1 - D_i(r).} \tag{3}$$

즉 **차량 검출 → 차량 픽셀 제외 → 같은 L2 베이킹**이다. DOTA YOLO11s-OBB 의 small/large vehicle 검출 (confidence0.25) 을 polygon 으로 채우고 5×5 팽창해 D_i 를 만든다. S 는 학습 중 고정한다. 원 Block-NeRF 의 Panoptic-DeepLab 을 항공영상용 검출기로 바꾼 베이킹 구현이며, 그림자를 별도로 제외하지는 않는다.

2.5 HuGS 형: 정적으로 일관된 영역만 사용

HuGS 형은 **정적 후보를 만들고 SAM 영역별로 확장해 S 를 고정**한다. 먼저 특징점이 반복 관측되는 영역 F_i 와 L2 warm-up 잔차가 작은 영역 C_i 를 합치고, 큰 잔차를 제한하는 Q_i 로 걸러 정적 후보를 만든다.

$$H_i = (F_i \cup C_i) \cap Q_i. \tag{4}$$

이 식의 H_i 는 핵심 결합 구조를 뜻하며, 구현에서는 여기에 국소 다수결 보정을 적용한다. F_i 는 20 개 입력 중 자기 자신 포함 5 개 이상에서 검증된 특징점의 SAM 영역, C_i 는 warm-up 잔차 평균 이하 영역이다. Q_i 는 95 분위수 이하 영역에 C_i 를 합친 제한 영역이다.

분리된 SAM 영역 m 에서 정적 후보가 차지하는 비율이 절반 이상이면 그 영역을 사용한다.

$$\boxed{S_i^{\text{HuGS}}(r) = \mathbf{1}\left[r \in \bigcup_{m:\,|m\cap H_i|/|m|\geq 0.5} m\right].} \tag{5}$$

표시 식은 영역 채택 기준이며, 실제 최종 마스크에는 5×5 erosion 도 적용한다. **특징점 지지↑, 낮은 잔차 → SAM 정적 영역 → 같은 L2 베이킹**의 흐름이다. 본 실험은 3D SfM track 대신 검증된 2D 매칭 지지 횟수를 사용했다. L2 warm-up600 회로 S 를 준비한 뒤 최종 베이킹은 공통 평균 초기값에서 다시 600 회 수행한다.

2.6 Robust 형: 현재 잔차로 S 를 반복 갱신

현재 RMS 색 잔차를 ε_i 라 한다. 각 영상에서 잔차 중앙값 이하인 픽셀을 임시 inlier a_i 로 고른다. 이후 주변 3×3 다수결과 16×16 문맥 검사를 거쳐 S 를 만든다.

$$a_i(r) = \mathbf{1}\left[\varepsilon_i(r) \leq \text{median}_{r\in\Omega_i}\,\varepsilon_i(r)\right], \tag{6}$$

$$W_i(r) = \mathbf{1}[B_3(a_i)(r) \geq 0.5], \tag{7}$$

$$S_i^{\text{Robust}}(r) = \text{stopgrad}(\mathbf{1}[B_{16}(W_i)(p_8(r)) \geq 0.6])\,. \tag{8}$$

B_k 는 $k \times k$ 평균, $p_8(r)$ 는 대응하는 8×8 타일의 중심이다. a_i 는 valid 밖에서 0 으로 둔다. **현재 잔차 → 공간적으로 안정된 inlier → 같은 L2 로 갱신 → 잔차 재계산**의 흐름이다. stopgrad 는 S 로의 gradient 를 끊는 연산이며, S 는 매 반복 갱신한다.

OR 변형은 저잔차↑, 이웃↑, 타일 판정을 OR 로 완화한다. 차량 크기 및 깊이 적응 변형은 차량 길이 4.5m, 초점거리, 지면 깊이로 문맥 크기를 바꾼다. 원래 L2 오차는 공통이며 달라지는 것은 S 의 공간적 선택 방식이다. 상세 수식은 부록에 둔다. 차량 관측이 다수이면 차량 쪽 잔차가 작아져 차량을 잘못 $S = 1$ 로 선택할 수 있다.

2.7 개선한 S: 원본 마스크를 공통 UV 에서 투영

기존 Block 형은 합성 사선 영상마다 독립 검출하므로 같은 연도의 같은 차량도 시점에 따라 마스크가 달라진다. 원본 정사영상의 마스크 D_t^{UV} 를 알려진 대응 ϕ_c 로 투영한다.

$$\boxed{S_{t,c}^{\mathrm{geo}}(r) = \mathbf{1}[D_t^{\mathrm{UV}}(\phi_c(r)) \le 0.05].} \tag{9}$$

$D_t^{\mathrm{UV}}(\phi_c(r))$ 는 bilinear 보간값이다. **연도별 UV 검출 → 같은 마스크를 각 카메라로 투영 → 같은 L2 베이킹**이 된다. Geometry mask 는 평균 초기값, Geometry + init 은 아래 UV 합성 초기값을 사용한다. 두 방법의 S 와 손실은 같다.

2.8 관측 선택을 공유하는 직접 UV 합성과 추가 prior

직접 UV 합성: 선택한 관측을 직접 모으는 참고 기준선. 원본에서 사용할 관측을 $S_t^{\mathrm{UV}}(u) = 1 - D_t^{\mathrm{UV}}(u)$ 로 둔다. 공통 UV 가 이미 알려져 있으므로 선택한 색을 직접 합성하는 방법도 비교한다.

$$\boxed{T_{\mathrm{UV}}(u) = \mathrm{median}_{t:\, S_t^{\mathrm{UV}}(u)=1}\, J_t(u).} \tag{10}$$

RGB 각 채널의 median 을 구하고, 모든 S 가 0 인 위치만 주변에서 보간한다. 실제 출력은 공통 512 격자를 거친다. **이 방식은 S 에 의한 관측 선택을 공유하지만 L2 베이킹의 해 자체는 아니다.** 최적화 대신 median 으로 합성하는 별도 추정기다. 마스크 없는 시간 중앙값도 별도 참고 기준선으로 둔다.

Shadow guard: S=0 의 범위를 어두운 이웃으로 확장. 차량 근처에서 주변보다 어두운 픽셀을 G_t 라 하면

$$\boxed{S_t^{\mathrm{guard}}(u) = (1 - D_t^{\mathrm{UV}}(u))(1 - G_t(u)).} \tag{11}$$

이 S 로 같은 UV 합성을 한다. G_t 는 차량에서 18texel 이내이면서 61×61 비차량 주변 평균 밝기의 0.72 미만인 영역이다. 그림자 정답 라벨이 아니므로 어두운 포장면도 제외할 수 있다.

Geometry + prior: S 는 유지하고 미관측부에 공간 제약 추가. 이 변형은 S^{geo} 자체를 바꾸지 않고 초기값과 목적함수를 확장한다.

$$\mathcal{L}_{\mathrm{geo+prior}} = \mathcal{L}_{\mathrm{bake}}(S^{\mathrm{geo}}) + 0.01\mathcal{L}_{\mathrm{TV}} + 0.05\mathcal{L}_{\mathrm{anchor}}. \tag{12}$$

TV 는 관측이 적은 곳을 더 강하게 평활화하고, anchor 는 미관측부를 UV 합성의 보간 초기값에 가깝게 묶는다. S **변경, 초기값 변경, 추가 정규화의 효과를 나눠 비교**하는 변형이다. 보간과 prior 는 실제 관측한 배경이 아니다. 상세 가중치와 보간 수식은 부록으로 분리했다.

2.9 추가 두 방법: 같은 S 를 유지하고 채우는 방식을 개선

앞의 실험에서 차량색을 제외하더라도 빈 곳을 매끄럽게 보간하면 지면 질감이 사라지거나 경계가 부자연스러울 수 있었다. 이를 관측 선택과 구분하기 위해 두 추가 방법은 모두 **동일한 shadow-guard 관측 선택** S^{guard} 를 사용하고, 선택 후 텍스처 구성만 바꾼다.2021–2025 년만 계산에 사용하며 2026 은 평가에만 사용한다. 아래 방법은 원 논문 재현이 아니라 본 실험에서 추가한 재구성 기준선이다.

Gradient harmonization: 관측값과 경계 변화량을 함께 맞추기. 기존 UV 합성、보간값을 F, 배경 관측 수를 n, 인접 texel 쌍을 (u, v) 라 한다. 양 끝에서 같은 연도의 $S^{\mathrm{guard}} = 1$ 인 관측끼리 색 차이를 구해 채널별 median 을 g_{uv} 로 둔다. 그런 관측이 없으면 $g_{uv} = 0$ 이다.

$$T_{\mathrm{grad}} = \arg\min_T \left\{ \sum_u \frac{n(u)}{5} \|T(u) - F(u)\|_2^2 + 2 \sum_{(u,v)} \|(T(v) - T(u)) - g_{uv}\|_2^2 \right\}. \tag{13}$$

첫 항은 관측이 많은 위치의 색을 유지하고 두 번째 항은 실제 관측에서 얻은 지면 경계ㆍ질감 변화량을 연결한다. 서로 다른 연도의 색을 픽셀별로 합칠 때 생기는 불연속을 줄이려는 방식이다.1024 격자에서 선형 시스템을 풀고 기존과 같은 512 기저를 거쳐 출력한다. 새 per-view 색변환 학습은 없다. 관측 없는 곳의 실제 무늬를 만들어낸다는 뜻은 아니며, 잘못된 guidance 는 경계도 흐리게 할 수 있다.

Patch transfer: 실제 관측된 주변 패치로 미관측부 채우기. 완전 미관측 집합 $\mathcal{U} = \{u : n(u) = 0\}$ 만 수정한다. 채우는 경계의 21×21 패치를 P 라 하고, 그 안에서 이미 알려진 문맥을 K 라 한다. 모든 픽셀에 배경 관측이 있는 donor 패치 Q 중 문맥 색 오차가 가장 작은 패치를 선택한다.

$$Q^* = \arg\min_{Q} \operatorname{mean}_{u \in K} \|F_P(u) - (F_Q(u) + \delta_Q)\|_2^2. \tag{14}$$

δ_Q 는 문맥의 채널별 median 색 차이를 ±0.12 로 제한한 값이다. 주변 160texel 안에서 5texel 간격으로 탐색하고 후보가 없으면 전체 donor 에서 찾는다. 선택 패치의 중심 9×9 중 미관측 픽셀만 복사하며 최대 2500 회 진행한다. 원래 관측한 texel 은 고정하고 미관측 경계의 3texel 안쪽에서 기존 보간값과 혼합한다. 탐색 예산 안에 채우지 못한 곳은 기존 조화 보간값을 유지한다. 이 donor 도 검출기 기반 배경이므로 누락 차량ㆍ다른 표식이 복사될 수 있다.

두 방법의 계수는 새 평가 전에 고정했다. 둘 다 600 회 역렌더링 베이킹이 아닌 직접 재구성이며, 결과는 같은 차량 OBB ㆍ같은 2026 기준 RGB 로 평가한다. 성공뿐 아니라 품질 저하도 함께 보고한다.

2.10 공통 구현: S 이외의 조건

연도별 정사영상을 4 카메라에 재투영해 학습 20 장을 만든다. 메쉬는 120×120m 지면 평면, 최적화 변수는 512^2, 출력은 1024^2, 합성 카메라 영상은 768×576 이다. 기울기는 0/20/35/45 도이며 실제 독립 사선 촬영이 아니다.

학습형은 Adam600 업데이트, batch4, 텍스처 lr0.025, 색변환 lr0.001 을 공유한다. 시점별 3×3 색변환과 bias 를 학습하고 2023 년 nadir 를 고정한다. Geometry + init/prior 를 제외하면 학습 5 년의 평균에서 시작한다. HuGS 는 별도 warm-up ㆍ SIFT ㆍ SAM 비용이 있고 직접 UV 합성에는 600 회 최적화나 학습 색보정이 없다. 결과를 비교할 때 이 차이를 유지한다.

2.11 평가 지표와 실험 간 차이

RGB 범위를 $[0, 1]$ 로 두고 평가 영역 Ω 의 기준영상 G 에 대해

$$\mathrm{MSE}_\Omega(T, G) = \frac{1}{3|\Omega|} \sum_{u \in \Omega} \|T(u) - G(u)\|_2^2, \tag{15}$$

$$\mathrm{PSNR}_\Omega = -10 \log_{10} \max(\mathrm{MSE}_\Omega, 10^{-12}). \tag{16}$$

Easy 에서는 지면 ROI 를 평가하는 $G_{\mathrm{cons}} = \mathrm{median}_{t=2021,\ldots,2026} J_t$ 와,16 개 반경 5 원형 표본을 평가하는 실제 2022 년 배경을 구분한다. 전자는 2026 을 포함한 consensus 이므로 독립 GT 가 아니며, 후자는 2022 년이 학습에도 포함되어 독립 hold-out 이 아니다. Easy 의 2026 정적 영역 역시 consensus 와의 RMS 차이 < 0.06 으로 선정해 완전히 독립적인 정답 평가는 아니다.

Hard 에서는 기존 비교 전에 고정한 차량 전체 OBB33 개 (B16,C17) 를 사용하고, 그중 학습 5 회 중 3–4 회 점유한 21 개 (B4,C17) 를 주 평가한다. OBBO 의 점유 횟수는

$$o(O) = \sum_{t=1}^{5} \mathbf{1}\left[\frac{|O \cap \{D_t^{\mathrm{UV}} = 1\}|}{|O|} \geq 0.55\right] \tag{17}$$

로 정의한다. 부분 차량 겹침을 포함하는 검출 proxy 로 정확한 주차칸 점유 정답은 아니다. 기준 $G = J_{2026}$ 은 해당 OBB 에서 실제 관측된 배경이다. 픽셀별 차량 검출 3–4 회 영역과 5 회 완전 차

폐 영역도 진단한다. 정적 대조영역은 학습 차량 검출이 없고 RGB 채널 표준편차 최댓값 < 0.08 이며 2026 년에도 팽창된 차량 검출이 없는 지면이다.

Hard 의 LPIPS 는 각 OBB 중심 80×80 crop 에서 윤곽 밖 RGB 를 정답으로 치환한 뒤 AlexNet LPIPS 를 계산한 객체 평균이다. Easy 지면 masked LPIPS 와 다르다. SSIM 도 전체 map 에서 OBB 영역을 평균하므로 주변 창 영향이 남는다. ghost 는

$$\mathrm{ghost}(O) = \frac{1}{|O|} \sum_{u \in O} \mathbf{1}\left[\|T(u) - J_{t_O}(u)\|_2^2 < \|T(u) - G(u)\|_2^2\right] \tag{18}$$

이며 t_O 는 해당 표본에 차량이 있는 학습 연도다. 검출기와 비교 RGB 에 의존하는 보조 지표이지 차량 존재 확률이 아니다. 무지지 영역은 최종 마스크를 UV 로 역투영했을 때 어떤 학습 관측도 지지하지 않는 texel 이다. 공간 기저와 보간을 통한 간접 영향은 받을 수 있다.

Hard 와 Improved 는 같은 고정 OBB 、같은 2026 RGB 、같은 지표 코드를 사용한다. Easy 와 Hard 는 평가 영역과 기준 RGB 가 달라 숫자를 직접 빼서 성능 변화로 해석하면 안 된다. 평가 위치 제안과 점유에 의미 마스크와 같은 DOTA 검출기를 사용했고 에이전트가 시각 확인했으며, 독립 사람 라벨 검증은 없다.

3 Result

3.1 Easy: 빈 배경 관측이 다수인 장면

Table 3: Easy 의 저장 결과 (seed42). 차량 표본은 16 개 작은 원, 지면 기준은 6 년 consensus 다. 검출 수는 같은 검출기를 사용한 보조 지표다.

방법	차량 표본	지면 PSNR	지면 SSIM	지면 LPIPS	2026 정적	검출 수
L2 (no-removal)	27.27	30.38	0.920	0.038	27.18	9
Temporal median	35.69	37.57	0.974	0.013	29.12	0
Block-type	31.56	30.85	0.934	0.033	27.30	0
HuGS-type	32.81	32.45	0.931	0.032	27.90	0
Robust (base)	38.02	28.06	0.882	0.062	26.81	18
Robust (OR)	38.09	29.96	0.904	0.045	27.78	3
Robust (car)	38.12	29.90	0.903	0.046	27.23	7
Robust (depth)	37.78	29.03	0.896	0.053	27.21	11

이 표의 작은 차량 위치 표본에서는 Robust 형이 좋은 값을 얻었지만, 넓은 지면、 hold-out 、검출 수에서는 오히려 악화될 수 있다. 기본 Robust 형은 작은 표본 PSNR38.02dB 인 동시에 지면 PSNR28.06dB 와 검출 18 개를 보였다. 작은 차체 중심 표본의 성공을 전체 차량 제거로 해석할 수 없는 사례다. L2 도 빈 관측의 다수 효과로 차량을 상당히 희석했고, 시간 중앙값도 강했다. 중앙값은 consensus 와 연산 방식이 비슷하다는 평가상 유리함도 있다.

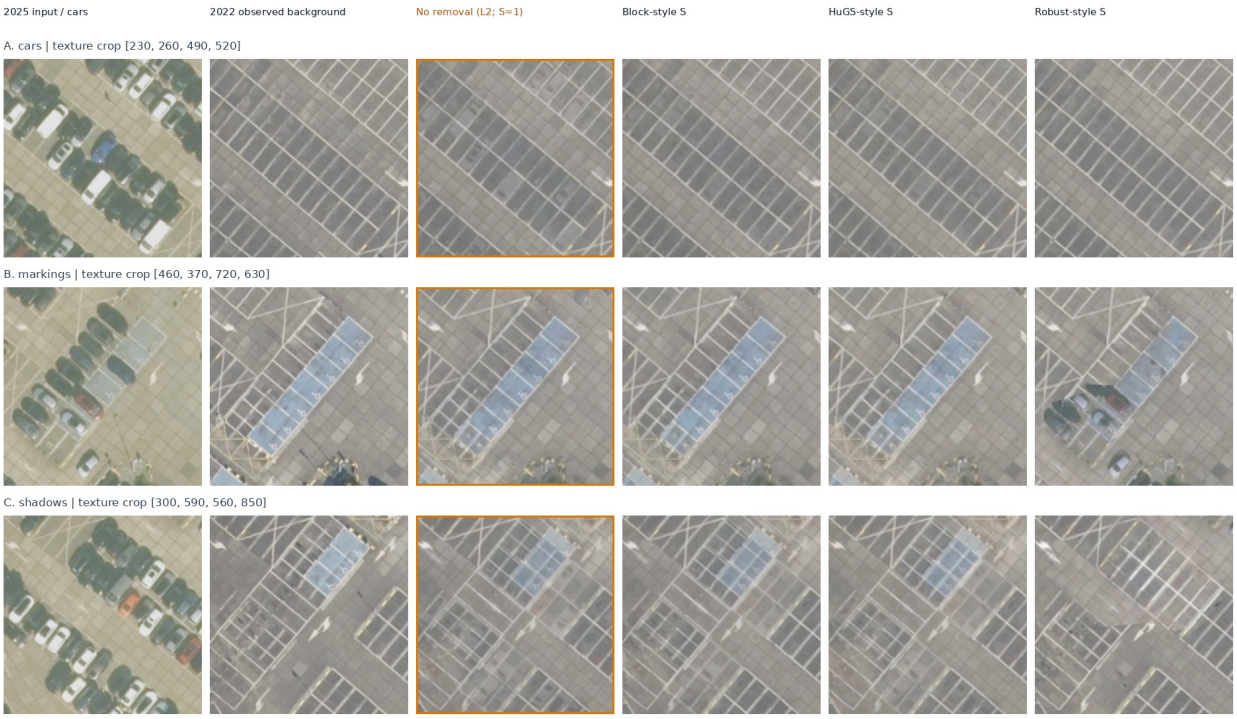


Figure 1: Easy 의 미적용 L2 포함 동일 위치 비교. 차량, 주차선, 명암 영역을 함께 보아 표본 점수와 넓은 지면 품질의 차이를 확인한다. 원 저장 결과에서 가져온 그림이며 추가 학습은 하지 않았다.

3.2 Hard: 높은 차량 점유에서의 기존 기준선

Table 4: Hard 의 기존 주요 기준선. 평균 ± 표본표준편차,3seed. 각 열은 PSNR(dB). B/C 의 3–4 회 점유 OBB 는 각각 4/17 개다.

장면	방법	3–4 회 점유 OBB	관측 가능한 hard 픽셀	정적 대조
B	L2 (no-removal)	19.01 ± 0.18	18.94 ± 0.17	21.97 ± 0.37
B	Block-type	19.94 ± 0.21	19.85 ± 0.20	21.85 ± 0.29
B	HuGS-type	18.16 ± 0.10	18.03 ± 0.10	21.01 ± 0.34
B	Robust (base)	14.49 ± 0.36	14.37 ± 0.37	19.71 ± 0.21
C	L2 (no-removal)	18.69 ± 0.24	19.17 ± 0.04	24.40 ± 0.35
C	Block-type	20.98 ± 0.19	22.24 ± 0.09	24.80 ± 0.09
C	HuGS-type	20.89 ± 0.09	21.67 ± 0.10	24.33 ± 0.13
C	Robust (base)	16.00 ± 0.40	16.80 ± 0.45	23.83 ± 0.08

기존 주요 4 방법 중 Block 형이 두 장면의 주평가 PSNR 에서 가장 높았지만 차량 전체가 사라지지는 않았다. Robust 형은 다수 시기에 반복되는 차량을 inlier 로 받아들이고 드문 배경을 제외할 수 있다. 시간 중앙값 역시 차량이 다수인 위치에서는 차체 RGB 를 선택할 수 있다. 그림자와 미관측 지면도 클래스 마스크만으로 해결되지 않는다.

Table 5: Hard 의 추가 변형 (seed42). PSNR 은 3–4 회 점유 OBB, LPIPS 는전체 채택 OBB crop 평균이다. 주요 표의 3seed 평균과 구분한다.

	B		C	
방법	PSNR	LPIPS	PSNR	LPIPS
L2 (no-removal)	18.93	0.147	18.87	0.335
Temporal median	18.48	0.119	18.85	0.338
Block-type	19.70	0.135	21.17	0.162
HuGS-type	18.12	0.129	20.97	0.174
Robust (base)	14.69	0.176	16.09	0.334
Robust (OR)	14.59	0.179	16.32	0.329
Robust (car)	14.04	0.189	18.38	0.277
Robust (depth)	14.23	0.175	16.74	0.299

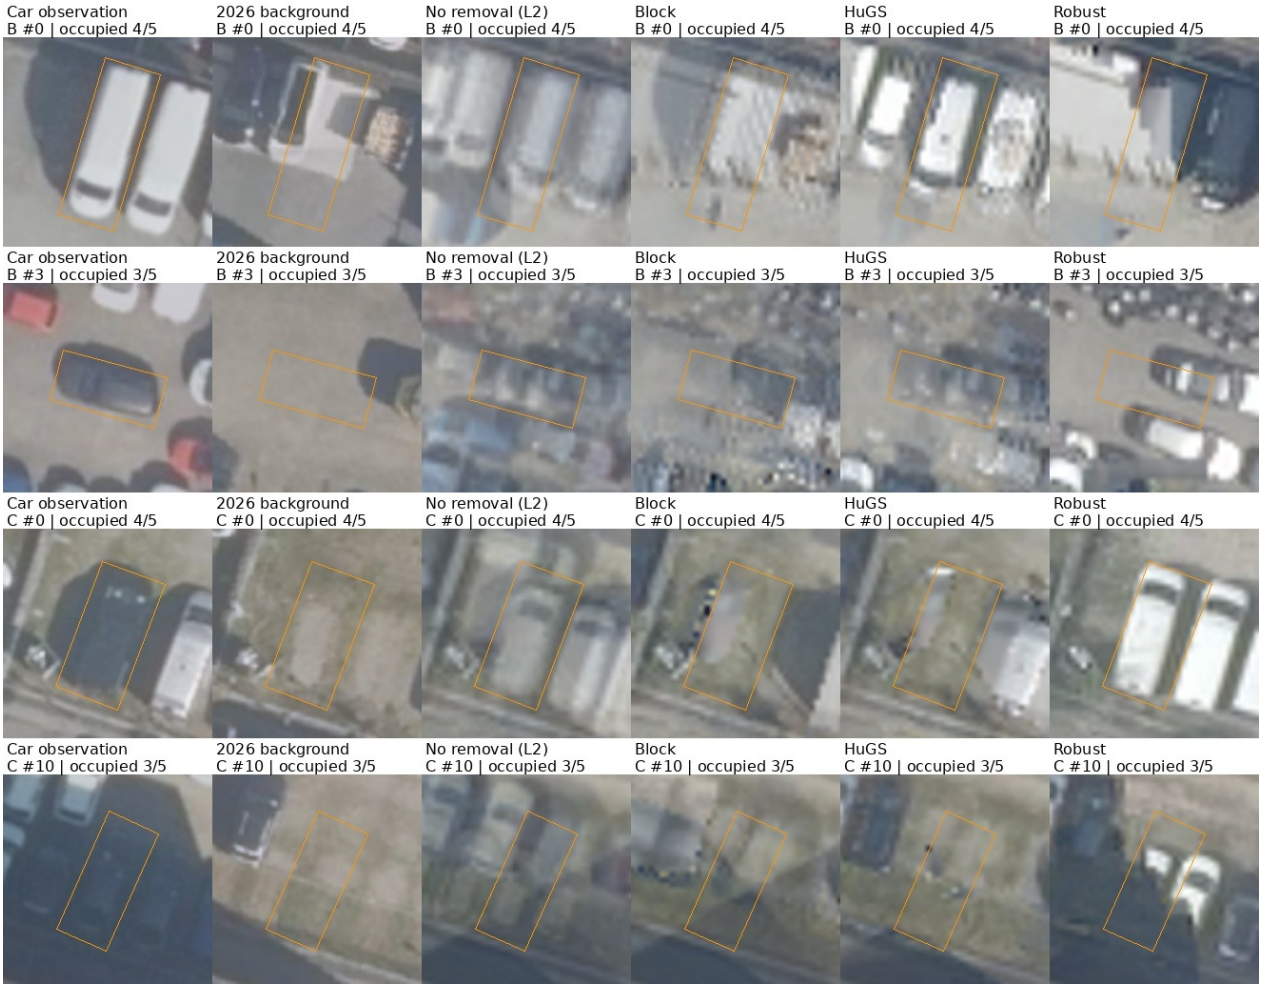


Figure 2: Hard 의 고정 위치 비교. 왼쪽부터 차량 학습 관측,2026 배경, L2, Block 형, HuGS 형, Robust 형이다. B 와 C 에서 각각 4/5 및 3/5 점유 표본을 사용하며 Improved 와 같은 위치다. 주황선은 고정 평가 OBB 다.

3.3 Improved: 배경 관측 선택과 명시적 공간 prior

Table 6: 동일 Hard 평가에서의 개선안. 학습형 PSNR 은 3seed 평균 ± 표본표준편차, 다른 열은 평균. UV 직접 합성 두 방법은 결정적 계산 1 회로 표준편차가 없다.

방법	B 차량 PSNR	C 차량 PSNR	B / C LPIPS	B / C 정적 PSNR
L2 (no-removal)	19.01 ± 0.18	18.69 ± 0.24	0.149 / 0.338	21.97 / 24.40
Block-type	19.94 ± 0.21	20.98 ± 0.19	0.136 / 0.165	21.85 / 24.80
HuGS-type	18.16 ± 0.10	20.89 ± 0.09	0.127 / 0.176	21.01 / 24.33
Robust (base)	14.49 ± 0.36	16.00 ± 0.40	0.173 / 0.342	19.71 / 23.83
UV fusion	20.81	22.10	0.085 / 0.146	24.51 / 26.62
UV + shadow guard	21.00	22.23	0.079 / 0.130	24.58 / 26.47
Geometry mask	19.95 ± 0.15	20.86 ± 0.09	0.118 / 0.183	21.68 / 24.89
Geometry + init	19.94 ± 0.17	21.33 ± 0.10	0.118 / 0.178	21.68 / 24.90
Geometry + prior	20.39 ± 0.23	21.74 ± 0.11	0.114 / 0.170	21.83 / 25.08

그림자 guard 를 추가한 UV fusion 은 Block 형에 비해 B 약 1.06dB, C 약 1.25dB 높았다. LPIPS 도 낮아졌다. 다만 guard 없는 UV fusion 과 비교하면 C 정적 대조 PSNR 은 26.62 에서 26.47dB 로 소폭 감소해, 모든 지표에서 일관된 개선은 아니다.

Geometry mask 만으로는 개선이 작았고, fusion 초기화의 이득도 600 회 최적화 후 일부 사라졌다. 공간 prior 는 Geometry + init 대비 주평가 PSNR 을 B 약 0.45dB, C 약 0.41dB 높였지만 직접 fusion 보다 낮았다. 알려진 평면 UV 에서는 직접 관측 합성이 역렌더링 최적화보다 유리한 실용 기준선이었다. 이 비교는 원래 NeRF 환경에서의 우열을 뜻하지 않는다.

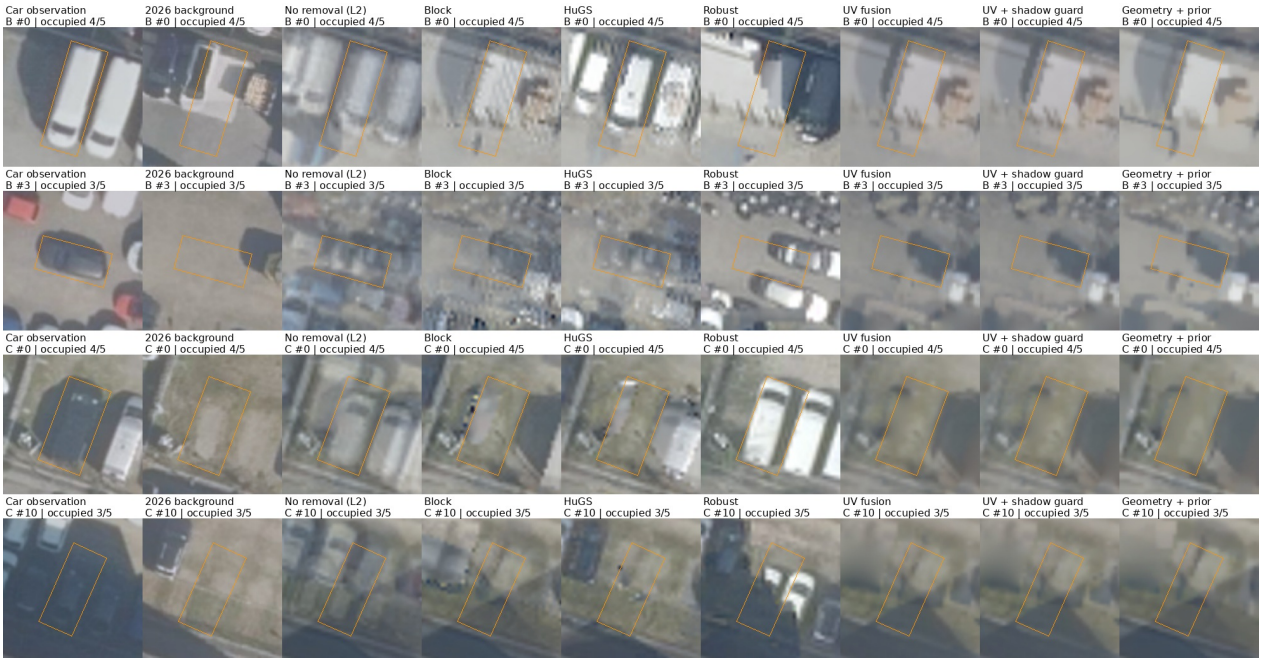


Figure 3: 동일 4 개 고정 차량 위치의 개선안 비교. 주황선은 평가 OBB 로 시각화에만 표시했다. 모든 결과는 seed42, 동일 crop 、동일 색 범위다. UV 합성에서 차체와 중첩 흔적은 줄지만 일부 어두운 흔적과 주변 차량은 남는다. 폴리곤 밖 인접 차량은 해당 표본 점수에 포함되지 않는다.



Figure 4: 전체 장면 비교. 윗줄 B, 아랫줄 C. 미적용 L2, Block 형, HuGS 형, Robust 형, UV fusion, UV+shadow guard, Geometry+prior 순서다. 미관측 영역의 보간、그림자、주변 잔류 차량까지 포함해 보아야 한다.

3.4 추가 실험: 부자연스러운 채움을 줄이는 두 재구성 방법

두 방법은 기존 UV+shadow guard 와 **동일한 관측 선택 S** 를 공유한다. 따라서 아래 차이는 차량 제외 마스크의 개선이 아니라 선택 후 색、질감을 구성하는 방식의 차이다. 계수는 평가 전에 고정했고, 동일한 두 장면、고정 33 개 OBB 、주요 21 개 OBB 、 2026 기준 RGB 를 재사용했다. 기존 54 행은 바꾸지 않고 두 방법 × 두 장면의 4 행을 추가했다.

Table 7: 추가 채움 방법의 동일 평가 비교. 기존 학습형은 3seed 평균 ± 표본표준편차, 직접 재구성은 결정적 1 회다. PSNR 은 dB, LPIPS 는전체 채택 OBB 의 객체 평균이다.

방법	B 차량 PSNR	C 차량 PSNR	B / C LPIPS	B / C 정적 PSNR
No removal (L2)	19.01 ± 0.18	18.69 ± 0.24	0.149 / 0.338	21.97 / 24.40
Block	19.94 ± 0.21	20.98 ± 0.19	0.136 / 0.165	21.85 / 24.80
UV fusion	20.81	22.10	0.085 / 0.146	24.51 / 26.62
UV + shadow guard	21.00	22.23	0.079 / 0.130	24.58 / 26.47
Gradient harmonize	20.82	22.32	0.077 / 0.125	24.62 / 26.56
Patch transfer	21.00	22.15	0.077 / 0.129	24.58 / 26.47

Gradient harmonization 은 UV+shadow guard 보다 OBB crop LPIPS 를 B0.079→0.077, C0.130→0.125 로 낮췄다. 정적 대조 PSNR 도 두 장면에서 소폭 높았다. 그러나 주요 차량 위치 PSNR 은 B21.00→20.82dB 로 하락하고 C22.23→22.32dB 로 상승했다. 이는 경계 연결을 다듬는 것과 절대 RGB 정답에 가까워지는 것이 항상 같지 않음을 보여준다. 질감이나 차선도 과도하게 부드러워질 수 있다.

Patch transfer 는 주요 PSNR 에서 B21.00dB 로 거의 같았고 C22.15dB 로 소폭 하락했다. 완전 미관측 OBB 픽셀만 보면 B20.19→23.69dB 로 개선됐지만 C18.74→18.29dB 로 악화됐다. 관측 지면의 무늬를 복사해도 다른 재질、표식、누락 차량을 가져올 수 있어 일관된 개선은 아니다.

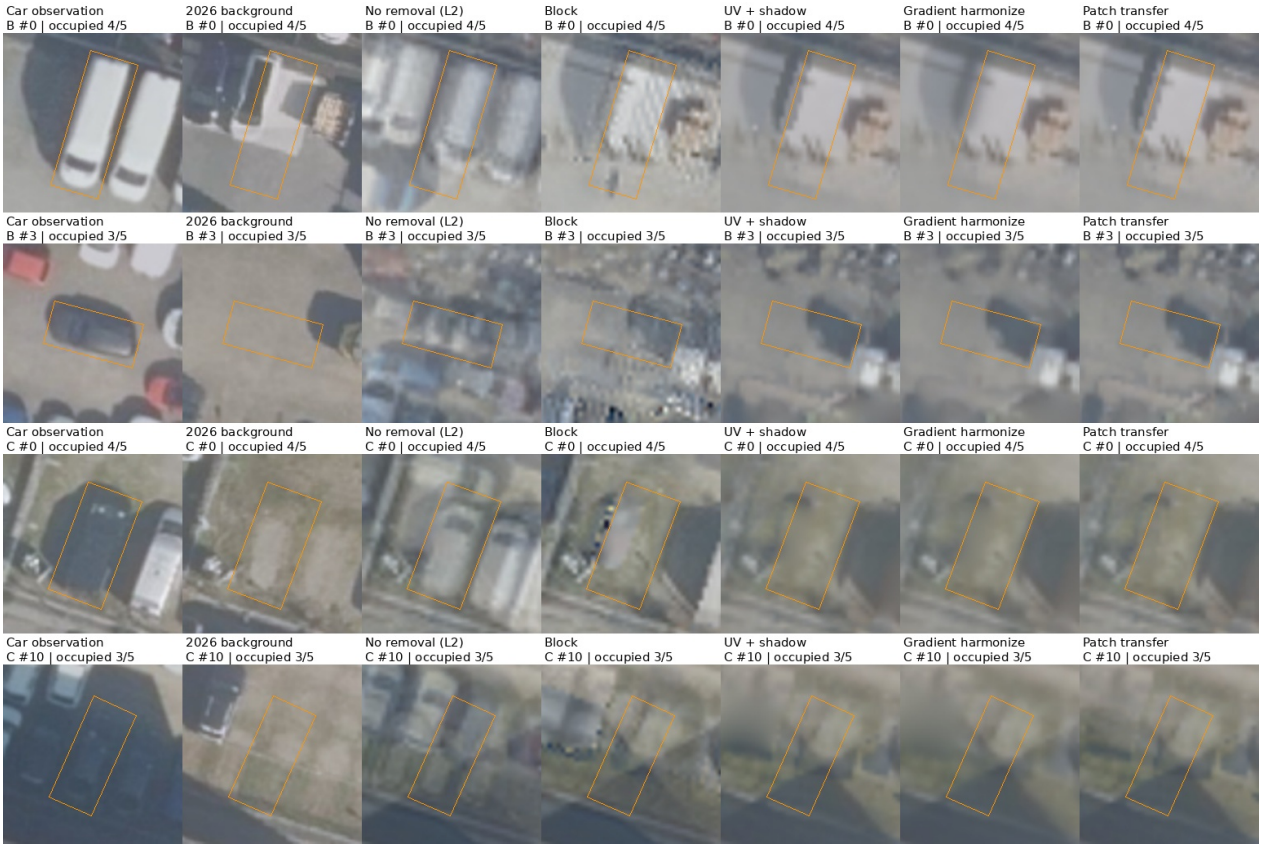


Figure 5: 새 두 방법을 같은 4 개 고정 차량 위치에 추가한 비교. 원본 차량 관측,2026 배경, L2, Block 형, UV+shadow guard, Gradient harmonization, Patch transfer 순서다. 주황선은 평가 OBB 이며 모든 방법에 동일한 crop 과 색 범위를 사용했다.

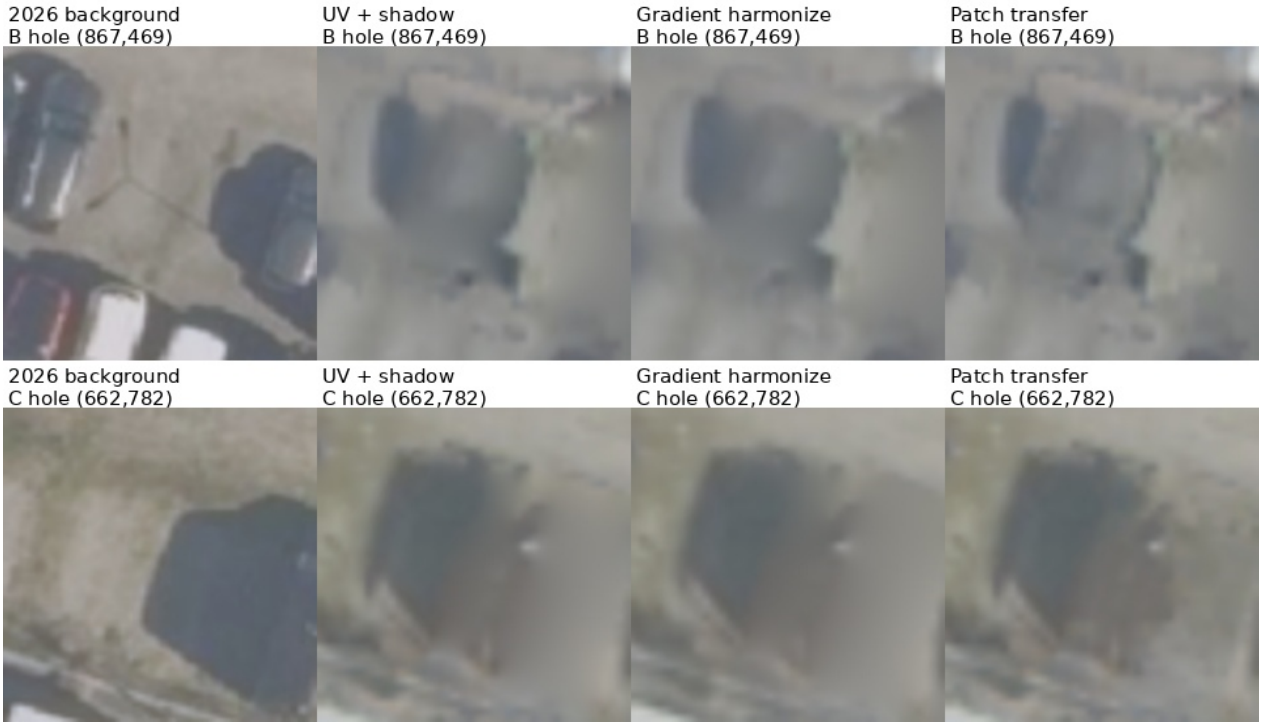


Figure 6: 채움 자체를 보기 위한 추가 확대. 고정 채택 OBB 와 겹치는 완전 미관측 연결성분 중 장면별 최대 영역을 원본 마스크만으로 선택했다. 좌표 선정에는 방법별 출력이나 평가 오차를 사용하지 않았다. 차체 모양의 어두운 흔적과 흐림은 여전히 남아 완전 해결을 뜻하지 않는다.

Table 8: 추가 진단 (seed42). Gradient L1 은 2026 기준과의 인접 RGB 차분 오차 (낮을수록 좋음), hole 은모든 학습 관측이 제외된 픽셀, 경계는 hole 의 3 픽셀 이웃이다. 작은 부분집합이며 자연스러움의 사람 평가가 아니다.

장면	방법	Gradient L1	hole PSNR	경계 PSNR	hole 픽셀
B	UV + shadow guard	0.0109	20.19	20.28	362
B	Gradient harmonize	0.0105	20.56	20.39	362
B	Patch transfer	0.0109	23.69	21.83	362
C	UV + shadow guard	0.0108	18.74	18.86	1439
C	Gradient harmonize	0.0103	18.55	19.06	1439
C	Patch transfer	0.0108	18.29	18.84	1439

추가 진단의 hole 표본은 B362 픽셀, C1439 픽셀로 작다. Gradient L1 은 실제 2026 RGB 의 인접 차분과의 오차이며, 두 장면 모두 감소했지만 **사람이 판단한 자연스러움 점수는 아니다.** 시기별 재질·조명 차이와 512 기저의 한계도 남는다. 완전 미관측 영역 이외에 남은 어두운 차량·그림자 흔적은 Patch transfer 의 수정 대상이 아니므로 그대로일 수 있다.

1024 격자에서 Gradient 선형계는 두 장면의 모든 채널이 정해진 허용 오차로 수렴했고 실행 시간은 B 약 9.4 초, C 약 6.7 초였다. 패치 전사는 B 약 62.7 초, C 약 67.0 초이며 2500 회 예산에서 전체 영상의 미관측부 중 B42.7%, C98.1% 를 새로 채웠다. 남은 B73109 픽셀, C1118 픽셀은 기존 조화 보간값을 유지했다. 이 비율은 지붕 등을 포함한 전체 영상 기준으로 평가 OBB 비율과 다르다. 시간은 이 환경의 단회 기록이며 일반적인 속도 비교가 아니다.

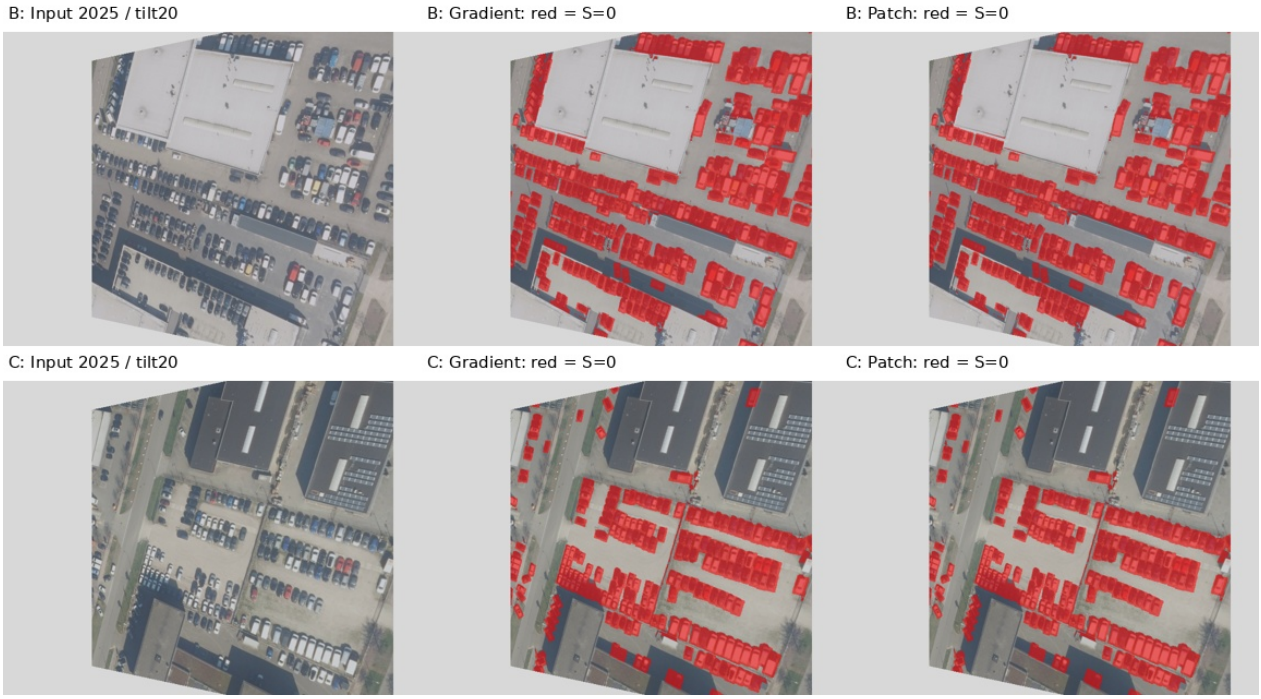


Figure 7: 추가 두 방법의 빨간 제외 마스크. 장면별 2025 년·20 도 입력이며 위 B, 아래 C 다. 두 방법 모두 같은 shadow-guard S 를 사용해 빨간 영역이 동일하다. 차이는 마스크가 아니라 선택된 관측으로 배경을 채우는 방식이다. 회색은 valid 밖이다.



Figure 8: 추가 방법을 포함한 전체 장면. L2, Block 형, UV fusion, UV+shadow guard, Gradient harmonization, Patch transfer 순서이며 위 B ·아래 C 다. 국소 개선뿐 아니라 남은 어두운 흔적·평활화·잘못 복사된 질감도 함께 평가한다.

두 추가 방법은 **부분적인 개선과 실패를 모두 보였다.** 이번 결과만으로 부자연스러운 채움 문제가

해결됐다고 결론내릴 수 없다. 관측 없는 배경의 정확한 무늬를 알려면 추가 시기 사진이나 더 신뢰할 수 있는 차량·그림자 분할이 필요하다. 실행 코드는 `harder_dataset/natural_fill/`, 전체 58행 CSV 와 추가 진단·선택 좌표·검증 기록은 같은 폴더의 `results/` 에 저장했다.

3.5 관측 선택의 시각화: 빨간색은 제외한 관측 S=0

수식의 S 가 실제로 어느 픽셀을 제외하는지 확인하기 위해 입력 사진에 마스크를 겹쳐 표시했다. 세 장면 모두 2025 년, 기울기 20 도 카메라, seed42 의 저장 마스크를 사용했다. **빨간색은 valid 중 $S < 0.5$ 인 제외 관측이며, 회색은 지면 투영의 valid 밖이다.** 패널의 제외 비율은 해당 입력의 valid 전체에서 계산한 값으로 평가 ROI 비율과 다르다. 같은 장면의 모든 패널은 동일한 입력、카메라、색 범위를 공유한다.

L2 는 차량도 사용하므로 빨간 영역이 없다. Block/HuGS 는 학습 전 고정한 선택, Robust 계열은 **최종 텍스처에서 재계산한 선택의 스냅샷**이다. Robust 의 빨간색은 학습 전체에서 한 번도 사용하지 않은 영역이라는 의미가 아니다. Geometry mask/init/prior 는 같은 S 를 공유하므로 하나의 패널로 표시했다. UV fusion 의 패널은 원본 UV 관측 선택을 같은 카메라로 투영한 것으로, 직접 합성이 별도 렌더 손실을 학습한다는 뜻은 아니다.

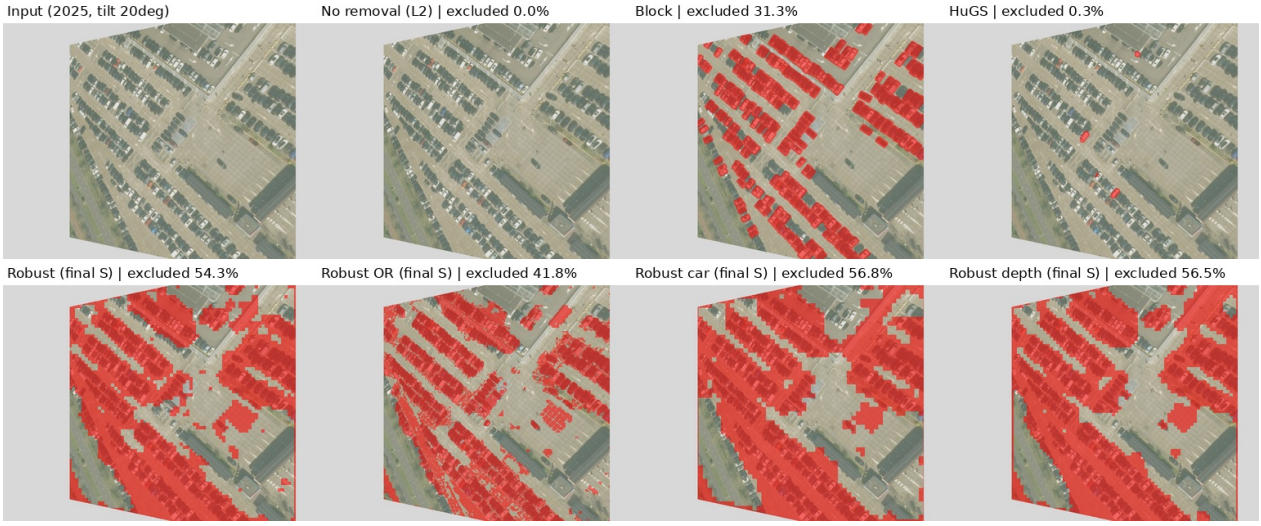


Figure 9: Easy 입력의 제외 영역. 윗줄은 원본, L2, Block 형, HuGS 형이며 아랫줄은 Robust 기본、 OR 、차량 크기、깊이 적응이다. 빨간색이 많다고 제거 품질이 높다는 의미는 아니며 주차선과 지면의 잘못된 제외도 함께 살핀다.

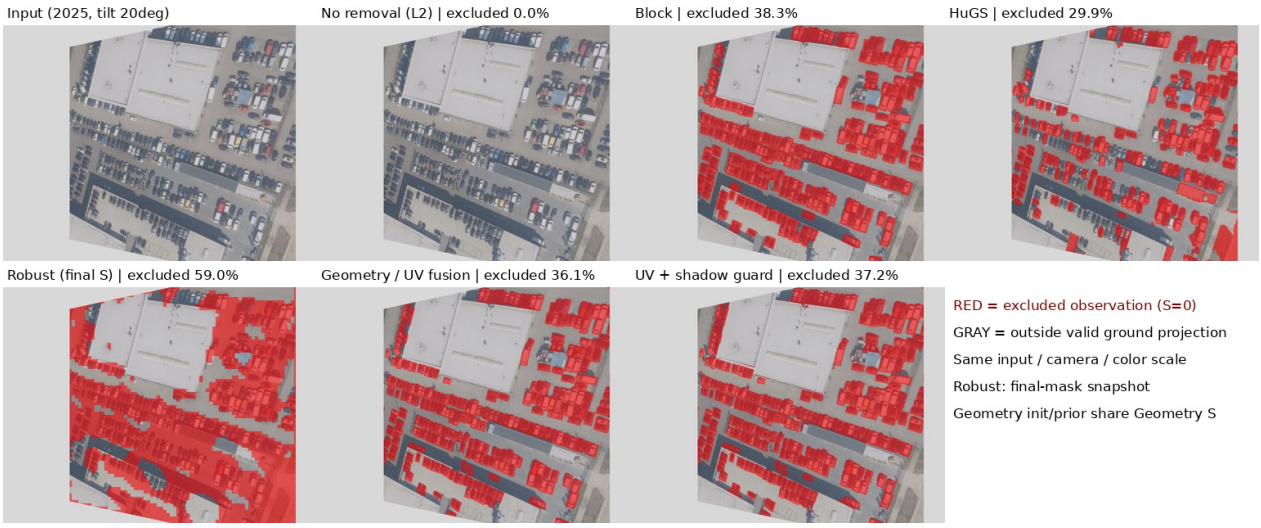


Figure 10: Hard B 의 제외 영역. 원본, L2, Block 형, HuGS 형, 최종 Robust 형, Geometry/UV fusion, UV+shadow guard 순서다. 원본 UV 마스크를 투영한 선택과 사선 영상별 독립 검출의 차이를 같은 사진에서 비교한다.

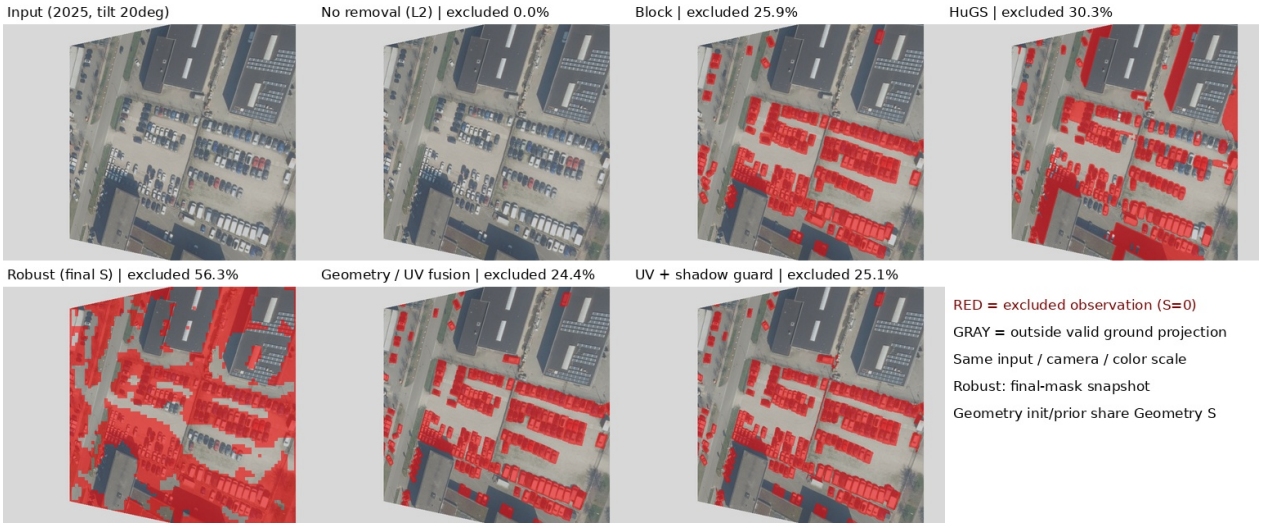


Figure 11: Hard C 의 제외 영역. B 와 같은 순서와 표시 규칙이다. Shadow guard 는 차체 마스크 밖의 어두운 이웃까지 제외할 수 있다. 빨간 영역은 차량·그림자의 정답 분할이 아니라 각 방법이 실제 사용하지 않는 관측이다.

3.6 해석, 한계 및 재현 범위

1. **관측 선택의 효과:** 잔차가 작다는 사실과 정적 배경이라는 사실은 다르다. 의미 마스크로 차량 관측을 제외하면 소수 배경도 사용할 수 있지만 검출 누락은 그대로 영향을 준다.
2. **복원과 보간의 구별:** 5 회 모두 가린 영역은 색을 직접 관측하지 못했다. 조화 보간、 TV 、 anchor 는 공간적 추정으로, 실제 배경의 정확한 복원을 입증하지 않는다. 차선과 작은 디테일 손실도 남는다.
3. **공정성의 범위:** 학습형은 동일 600 회、동일 Adam 설정이지만 HuGS 는 추가 warm-up/SIFT/SAM 비용이 있다. 직접 fusion 은 최적화가 없고 학습형 affine 색보정도 없으므로 계산 비용、모델군까지 같지는 않다. 원 중앙값 참고 기준선은 512 기저도 거치지 않았다.
4. **통계와 평가:** 3seed 의 표준편차는 동일 장면의 최적화 변동이며 독립 3 장면이나 신뢰구간이 아니다. Hard 주평가는 B4 개, C17 개로 작고 불균형하다. detector 기반 위치、점유와 실제 2026 년의 조명、토양、계절 변화에 따른 편향이 남는다.
5. **설계와 일반화:** Improved 는 같은 benchmark 의 이전 실패를 보고 설계했다.2026 RGB 나 annotation 을 fusion 、최적화에 쓰지는 않았지만 외부 미관측 데이터 검증으로 해석할 수 없다. 반합성 카메라는 실제 사선 촬영의 3D parallax 가 없고, 두 Hard 장면도 같은 산업지구다.

현재 조건의 실용적 기준선은 비차량 UV fusion 이며, 어두운 흔적을 줄이려면 고정 shadow guard 를 함께 비교할 수 있다. 전체 차량 제거의 보증이 아닌 개선된 출발점이다. 본 통합 문서는 저장된 실험을 재정리한 것이며 새 학습이나 평가 영역 변경은 수행하지 않았다.

3.7 산출물과 실행 기록

원 프로젝트 기준 주요 파일은 다음과 같다.

- Easy: `PROJECT_EASY_PILOT.md`, `pilot.py`, `results/metrics.csv`, `results/manual_metrics.csv`.
- Hard: `PROJECT_HARD_BASELINES.md`, `harder_dataset/run_scene.py`, `harder_dataset/evaluate_harder.py`, `harder_dataset/results/metrics.csv`.
- Improved: `PROJECT.md`, `harder_dataset/improved_baselines/train.py`, `shadow_guard.py`, `protocol.json`, `shadow_protocol.json` (마지막 3 개도 같은 improved 디렉터리).
- 통합 지표: `harder_dataset/improved_baselines/results/combined_metrics.csv`.54 행은 기존 32 행과 신규 22 행이다. 신규는 18 개 600 회 학습 실행과 4 개 결정적 fusion 이다.
- 신규 검증: `harder_dataset/improved_baselines/results/validation.json`. 관측 median 보존, 마스크、수치 유효성, 반복 예산, 기존 L2 점수 동일 재계산을 확인했다.
- 이 LaTeX 폴더의 `source_manifest.json` 에 통합에 사용한 문서、코드、지표의 체크섬을 남겼다. 표는 저장된 CSV 에서 생성했으며 새 수치를 추정하지 않았다.

A 구현 세부 수식

본문은 관측 선택 S 의 차이를 중심으로 설명했다. 여기서는 같은 실행을 정확히 재현하기 위한 정규화、형태학 처리、보간、정규화항의 상세 수식을 모았다.

A.1 표기와 공통 베이킹 모델

연도를 $t \in \{1, \dots, 5\}$, 합성 카메라를 $c \in \{0, 1, 2, 3\}$, 입력 번호를 $i = (t, c)$ 로 둔다. $J_t(u) \in [0, 1]^3$ 는 정합、노출 정규화된 정사영상의 UV 위치 u 의 색이다. $\phi_c(r)$ 는 카메라 픽셀 r 에서 지면 UV 로 가는 homography 다.

$$I_{t,c}(r) = J_t(\phi_c(r)), \qquad T_\theta = U_{512\to1024}(\theta), \quad \theta \in [0, 1]^{512\times512\times3}. \tag{19}$$

U 는 bilinear 보간이며 구현은 `align_corners=True` 를 사용한다. 평면 메쉬는 $x, y \in [-60, 60]$m, $z = 0$ 이다. 카메라는 원점을 바라보며 중심 거리 100m, 초점거리 480px, 출력 768×576 이다. 기울기/방위는 $(0, 0), (20, 0), (35, 100), (45, 220)$ 도다. 기울어진 카메라의 고도는 $100\cos(\text{기울기})$m 이므로 거리와 고도를 혼동하면 안 된다.

학습 예측과 RGB 평균 제곱 오차는

$$P_i(r) = A_i\, R(M, T_\theta; \pi_c)(r) + b_i = A_i\, T_\theta(\phi_c(r)) + b_i, \tag{20}$$

$$e_i(r) = \frac{1}{3}\|P_i(r) - I_i(r)\|_2^2, \qquad \varepsilon_i(r) = \sqrt{e_i(r)}. \tag{21}$$

$A_i \in \mathbb{R}^{3\times3}, b_i \in \mathbb{R}^3$ 는 시점별 색보정이다. $V_c(r)$ 는 평면 내부의 valid 마스크이며 차량 마스크 $S_i(r)$ 및 평가 ROI 와 다르다. 정규화 텍스처 좌표의 최댓값이 0.98 이하인 곳만 valid 로 둔다.

선택한 영상 batch $\mathcal{B}$ 의 실제 목적함수는

$$\mathcal{L}_{\text{data}} = \frac{\sum_{i\in\mathcal{B}} \sum_r V_c(r) S_i(r) e_i(r)}{\max(1, \sum_{i\in\mathcal{B}} \sum_r V_c(r))}, \tag{22}$$

$$\mathcal{L}_{\text{color}} = 10^{-3}\left[\text{mean}_{i,a,b}(A_i - I_3)_{ab}^2 + \text{mean}_{i,a}(b_i)_a^2\right], \tag{23}$$

$$\mathcal{L}_{\text{bake}} = \mathcal{L}_{\text{data}} + \mathcal{L}_{\text{color}}. \tag{24}$$

분모는 $\sum VS$ 가 아니라 $\sum V$ 다. 따라서 S 가 작아지면 데이터항의 규모도 감소하고, 동일한 정규화 계수의 상대 영향은 커질 수 있다. 이는 실제 구현의 공통 조건이지 유효 관측 수 보정이 아니다. $A_i = I_3, b_i = 0$ 에서 시작하고 2023 년 nadir 의 색보정을 고정해 색 좌표의 기준으로 삼는다.

A.2 공통 최적화 절차

기본 초기값은 $\theta^{(0)} = D_{1024\to512}(\frac{1}{5}\sum_t J_t)$ 이다. 매번 20 개 학습 영상 중 4 개를 뽑고, 렌더、색보정、마스크 생성、손실 계산、역전파、 Adam 갱신、 $[0, 1]$ clamp 를 수행한다. 최적화는 600 회의 optimizer update 이며 600 epoch 가 아니다. 텍스처 학습률은 0.025, 색보정은 0.001 이다. Easy 는 seed42, Hard 주요 4 방법과 학습형 개선안은 seed42/43/44 를 사용했다. 메쉬, 카메라, 입력 영상은 최적화하지 않는다. 최종 텍스처는 특정 카메라의 색보정을 적용하지 않은 T_θ 다.

A.3 미적용 기준선: L2 와 시간 중앙값

L2 / no-removal. 모든 valid 관측을 쓰므로 $S_i(r) \equiv 1$ 이다. L2 norm 자체는 $\|x\|_2 = \sqrt{\sum_k x_k^2}$ 지만 여기서 L2 손실은 그 제곱의 RGB 평균, 즉 MSE 다. 모델 이름이나 가중치 decay 를 뜻하지 않는다. 색보정과 카메라 재표본화를 생략하고 한 texel 만 보면

$$\arg\min_z \sum_{t=1}^{5} \|z - J_t(u)\|_2^2 = \frac{1}{5}\sum_{t=1}^{5} J_t(u). \tag{25}$$

따라서 빈 배경이 다수이면 차량이 희석되고 차량이 다수이면 그 색이 남는다. 이 평균식은 직관을 위한 단순화로 실제 600 회 베이킹이 정확한 시간 평균과 같다는 뜻은 아니다.

시간 중앙값.

$$T_{\text{median},k}(u) = \text{median}_{t=1,\dots,5}\, J_{t,k}(u), \quad k \in \{R, G, B\}. \tag{26}$$

이 채널별 중앙값은 $\sum_t |z - J_{t,k}(u)|$ 의 최소화 해다. 다수 오염에 약하며 RGB 채널별 선택값이 서로 다른 연도에서 올 수도 있다. 원래 중앙값 참고 기준선은 1024 격자의 사진에 직접 적용하고 512 기저 베이킹은 거치지 않았다. 뒤의 UV fusion 은 공통 512 기저를 거친다.

A.4 Block-NeRF 형: 의미 클래스에 따른 관측 제외

검출된 차량 OBB 집합을 $\mathcal{O}_i$ 라 하면

$$D_i(r) = \mathbf{1}\left[r \in \text{dilate}_{5\times5}\left(\bigcup_{o\in\mathcal{O}_i} \text{polygon}(o)\right)\right], \qquad S_i^{\text{Block}}(r) = 1 - D_i(r). \tag{27}$$

DOTA 사전학습 YOLO11s-OBB 의 small/large vehicle(class9/10), confidence0.25, 최대 1000 개를 사용했다. 이 S 는 고정한다. 원 Block-NeRF 의 Panoptic-DeepLab 을 항공영상용 OBB 검출기로 바꿨으며, 알려진 포즈를 사용하므로 COLMAP 마스킹은 생략했다. 차체 누락과 그림자는 남을 수 있고, 모든 시기에 가린 지면은 마스크만으로 알아낼 수 없다.

A.5 NeRF-HuGS 형: 특징점 지지, 잔차와 SAM 영역

특징점 일관성. 20 개 영상의 모든 쌍에 SIFT ratio0.75 와 homography RANSAC2px 를 적용한다. 특징점 j 가 검증된 매칭으로 지지받는 서로 다른 영상 수를 자기 자신을 포함해 n_{ij} 로 두면

$$q_{ij} = \mathbf{1}[n_{ij} \geq 5] = \mathbf{1}[n_{ij}/20 \geq 0.25]. \tag{28}$$

$q_{ij} = 1$ 인 특징점을 SAM 의 양성 point prompt 로 주어 정적 후보 영역 F_i 를 만든다. 3D SfM track 이 아닌 2D 매칭 지지의 대체다. 동일 연도 합성 4 시점도 지지를 제공하므로 시간적 정적성의 완전한 증거가 아니다. SAM ViT-B 를 사용하며 point 후보는 예측점수 > 0.8, stability≥ 0.92 를 통과시킨다. F_i 에는 5box 다수결 영역을 합친다.

색 잔차. L2 베이킹 600 회로 얻은 warm-up 잔차를 $\varepsilon_i^{\text{warm}}$ 이라 하면 valid 픽셀에서 평균 μ_i 와 95 분위수 q_i^{95} 를 계산한다.

$$C_i = \{r : \varepsilon_i^{\text{warm}}(r) \leq \mu_i\}, \tag{29}$$

$$Q_i = \{r : \varepsilon_i^{\text{warm}}(r) \leq q_i^{95}\} \cup C_i, \tag{30}$$

$$H_i^0 = (F_i \cup C_i) \cap Q_i, \tag{31}$$

$$H_i = H_i^0 \cup \{r : B_7(\mathbf{1}[H_i^0])(r) \geq 0.5\}. \tag{32}$$

B_k 는 $k \times k$ box 평균이다. Q_i 에 C_i 를합치는 것은 공식 구현에서 가져온 예외이며, 분위수만으로 자르는 식과 구별된다.

SAM 영역 선택. 자동 SAM 영역을 큰 것부터 덮어써 작은 영역이 겹침을 우선 차지하게 하고, 남은 부분은 연결성분으로 나눠 분리 영역 $m_{i\ell}$ 을 만든다. 영역별 정적 후보 비율이 0.5 이상이면 채택한다.

$$S_i^{\text{HuGS}} = \mathbf{1}\left[r \in \text{erode}_{5\times5}\left(\bigcup_{\ell:\, |m_{i\ell}\cap H_i|/|m_{i\ell}|\geq 0.5} m_{i\ell}\right)\right]. \tag{33}$$

자동 SAM 은 64 points/side, crop1, IoU0.8, stability0.9 를 사용한다. 최종 학습은 warm-up 텍스처를 이어받지 않고 공통 평균에서 다시 600 회 시작한다. 고정한 SIFT/SAM 캐시에 최종 512 기저 L2 의 잔차를 반영했다. warm-up 과 마스크 계산의 추가 비용이 있어 총 계산량이 다른 방법과 같지는 않다.

A.6 RobustNeRF 형: 잔차 기반 IRLS 와 공간 문맥

최적화 반복을 s 라 하자. 본 구현은 배치의 각 영상에서 valid RMS 잔차의 중앙값을 따로 계산한다. 이는 batch 전체 하나의 중앙값과 다르다.

$$\tau_i^{(s)} = \text{median}_{r:V_c(r)=1}\, \varepsilon_i^{(s)}(r), \tag{34}$$

$$a_i^{(s)}(r) = V_c(r)\mathbf{1}[\varepsilon_i^{(s)}(r) \le \tau_i^{(s)}], \tag{35}$$

$$W_i^{(s)}(r) = \mathbf{1}[B_3(a_i^{(s)})(r) \ge 0.5]. \tag{36}$$

$p_h(r)$ 는 r 을 포함하는 $h \times h$ 타일의 중심 좌표다. 16×16 문맥 평균을 8 타일 중심에서 샘플링해 타일 전체에 한 판정을 적용한다.

$$\omega_i^{(s)}(r) = \mathbf{1}[B_{16}(W_i^{(s)})(p_8(r)) \ge 0.6], \qquad S_i^{(s)}(r) = \text{stopgrad}(\omega_i^{(s)}(r)). \tag{37}$$

식(22)에 이 S 를 넣고 다음 최적화를 수행한다. S 에는 gradient 를 흘리지 않으며 매 반복 다시 만든다. 학습 종료 후 저장한 S 는 마지막 텍스처에서 재계산한 것으로 전체 반복의 평균이 아니다. 기본 fixed box 는 zero padding / SAME 을, 가변 box 는 영상 경계에서 잘라진 실제 면적 정규화를 사용한다.

OR 변형. 기본식에 단순히 최종 OR 하나만 넣는 것이 아니라 두 단계 모두 합친다.

$$W_i^{\vee} = \mathbf{1}[B_3(a_i) \ge 0.5] \vee a_i, \tag{38}$$

$$S_i^{\vee}(r) = \text{stopgrad}\left(\mathbf{1}[B_{16}(W_i^{\vee})(p_8(r)) \ge 0.6] \vee W_i^{\vee}(r)\right). \tag{39}$$

기본은 전달된 서베이의 OR 없는 해석이며, OR 은 MultiNeRF 구현에서 착안한 베이킹 변형이다.

차량 크기 변형. 차량 길이 $L = 4.5\text{m}$, 초점거리 $f = 480\text{px}$, 카메라 전방축 깊이 $D_c(r)$ 를 사용해 영상별 문맥 크기를

$$k_c = \left\lceil \text{median}_{r:V_c(r)=1}\, \frac{Lf}{D_c(r)} \right\rceil, \qquad h_c = \max(4, \lfloor k_c/2 \rfloor) \tag{40}$$

로 둔다. 식(37)의 B_{16}, p_8 을 각각 B_{k_c}, p_{h_c} 로 바꾼다. 초기 3box 는 그대로다.

깊이 적응 변형.

$$k_c(r) = \text{clip}\left(\left\lceil \frac{Lf}{D_c(r)} \right\rceil, 8, 64\right), \qquad S_i(r) = \text{stopgrad}\left(\mathbf{1}[B^{\text{variable}}_{k_c(p_8(r))}(W_i)(p_8(r)) \ge 0.6]\right). \tag{41}$$

가변 box 는 integral image 로 계산한다. 문맥만 깊이에 따라 바꾸며 내부 타일은 8 로 고정한다. Lf/D 는 차량 화면 크기의 근사로 방향과 foreshortening 까지 정확히 모델링하지 않는다.

A.7 개선 기준선 I: UV 에서 비차량 관측만 합성

원본 UV 에서 검출한 연도별 차량 마스크를 $D_t^{\text{UV}}(u)$, 사용 가능한 배경 관측을 $C_t(u) = 1 - D_t^{\text{UV}}(u)$ 라 하자. $n(u) = \sum_{t=1}^{5} C_t(u)$ 이다.

$$F_k(u) = \text{median}_{t:C_t(u)=1}\, J_{t,k}(u), \qquad n(u) > 0. \tag{42}$$

무마스크 중앙값과 달리 차량 검출 관측을 중앙값 계산 전에 제외하므로, 비차량 관측이 소수여도 사용할 수 있다. 단 마스크가 틀리면 남은 중앙값도 차량일 수 있다.

완전 미관측 집합을 $\mathcal{U} = \{u : n(u) = 0\}$ 라 하자. 먼저 가장 가까운 $n > 0$ 위치의 색으로 채운 $F^{(0)}$ 를 만든 뒤 256 회 Jacobi 갱신을 한다.

$$F^{(s+1)}(u) = \begin{cases} \frac{1}{4}\sum_{v\in\mathcal{N}_4(u)} F^{(s)}(v), & u \in \mathcal{U}, \\ F^{(0)}(u), & u \notin \mathcal{U}. \end{cases} \tag{43}$$

영상 경계는 reflect 처리한다. 이는 관측 위치에 Dirichlet 조건을 둔 조화 보간의 유한 반복 근사이며, 정확한 수렴 해를 보장하지 않는다. 미관측 위치는 실제로 관측한 배경이 아니라 공간적 추정이다. 마지막으로

$$\theta_F = D_{1024\to512}(F^{(256)}), \qquad T_{\mathrm{UV}} = U_{512\to1024}(\theta_F) \tag{44}$$

를 출력한다. 다운/업샘플링 전에는 알려진 관측 median 을 보존하지만 최종 출력의 모든 texel 이 그 median 과 정확히 같지는 않다. 별도 역렌더링 최적화나 시점별 색변환 학습을 하지 않으며 공통 전처리 색 정규화만 사용한다.

A.8 개선 기준선 II: 차량 주변의 어두운 후보 제외

밝기는 $\ell_t = 0.299J_{t,R} + 0.587J_{t,G} + 0.114J_{t,B}$ 다. 비차량 주변 밝기, 근접 집합과 추가 제외 마스크를

$$\bar{\ell}_t(u) = \frac{B_{61}(\ell_t C_t)(u)}{\max(B_{61}(C_t)(u), 0.05)}, \tag{45}$$

$$N_t(u) = \mathrm{dilate}_{\mathrm{ellipse}(37\times37)}(D_t^{\mathrm{UV}})(u), \tag{46}$$

$$G_t(u) = N_t(u)\mathbf{1}[\ell_t(u) < 0.72\bar{\ell}_t(u)], \tag{47}$$

$$D_t^{\mathrm{guard}}(u) = D_t^{\mathrm{UV}}(u) \vee G_t(u) \tag{48}$$

로 둔다. 반경 18texel 의 ellipse 이며 1024 격자에서 약 2.1m 다. D_t^{UV} 를 D_t^{guard} 로 바꿔 식(42)–(43)을 동일하게 적용한다. G_t 는 그림자 정답이 아니므로 어두운 도로·표식도 제외할 수 있다. 첫 개선안의 잔류 어두운 흔적을 보고 추가한 탐색적 변형으로, 계수는 변형 평가 전에 고정했고 임계값 grid search 는 수행하지 않았다.

A.9 개선 기준선 III: 마스크 투영·초기화·공간 prior

Geometry mask. 원본 UV 의 마스크를 알려진 기하로 투영한다. bilinear 샘플 값을 $\widehat{D}_{t,c}(r) = D_t^{\mathrm{UV}}(\phi_c(r))$ 라 하면

$$S_{t,c}^{\mathrm{geo}}(r) = \mathbf{1}[\widehat{D}_{t,c}(r) \le 0.05]. \tag{49}$$

각 사선 영상에서 독립 검출하는 Block 형과 달리 한 연도의 4 시점 마스크가 같은 UV 검출에서 나온다. 평균 초기화와 공통 600 회 베이킹은 유지한다.

Geometry + init. 같은 S^{geo} 를 사용하되 평균 초기값을 θ_F 로 바꾼다. 목적함수는 공통 $\mathcal{L}_{\mathrm{bake}}$ 다.

Geometry + prior. 512 격자에서 area 리샘플링한 관측 비율을 $q = D_{\mathrm{area}}(n/5)$ 라 두고 $w = 1/(1+5q)$, $a = \mathbf{1}[q < 0.01]$ 로 둔다. 인접 가중치는 $w_{uv}^x = (w_{u+1,v} + w_{u,v})/2$ 및 w^y 로 정의한다.

$$\mathcal{L}_{\mathrm{TV}} = \mathrm{mean}_{u,v,k}\left[w_{uv}^x|\theta_{u+1,v,k} - \theta_{u,v,k}|\right] + \mathrm{mean}_{u,v,k}\left[w_{uv}^y|\theta_{u,v+1,k} - \theta_{u,v,k}|\right], \tag{50}$$

$$\mathcal{L}_{\mathrm{anchor}} = \mathrm{mean}_{u,v,k}\left[a_{uv}(\theta_{uvk} - \theta_{F,uvk})^2\right], \tag{51}$$

$$\mathcal{L}_{\mathrm{geo+prior}} = \mathcal{L}_{\mathrm{bake}} + 0.01\mathcal{L}_{\mathrm{TV}} + 0.05\mathcal{L}_{\mathrm{anchor}}. \tag{52}$$

TV 는 차분이 정의되는 각 방향 격자 전체의 평균이고, anchor 도 미관측 개수만이 아닌 전체 512 격자 · 채널의 평균이다. 배경 관측이 적을수록 평활화를 더 강하게 하고 완전 미관측 초기값에서 지나치게 벗어나지 않게 한다. 차선과 경계도 흐려질 수 있다. 그림자 guard 마스크는 이 세 학습형 개선 안에는 추가하지 않았다.

References

[1] PDOK / Beeldmateriaal Nederland. Luchtfoto RGB open. https://www.pdok.nl/introductie/-/article/pdok-luchtfoto-rgb-open-. 출처 · 라이선스 안내: https://www.beeldmateriaal.nl/dataroom.

[2] Tancik et al. Block-NeRF: Scalable Large Scene Neural View Synthesis. CVPR, 2022. 본 실험은 의미 클래스 마스킹 아이디어를 차용하고 항공 OBB 검출기로 대체했다.

[3] NeRF-HuGS, 공식 구현. https://github.com/cnhaox/NeRF-HuGS. 마스크 생성 코드: `HuGS/generate_static_mask.py`. 본문 수식은 본 실험의 실제 대체 구현을 기술한다.

[4] Sabour et al. RobustNeRF: Ignoring Distractors with Robust Losses. CVPR, 2023. 공식 Multi-NeRF 코드: https://github.com/google-research/multinerf/blob/main/internal/robustnerf.py.

[5] Kirillov et al. Segment Anything. ICCV, 2023. https://github.com/facebookresearch/segment-anything.

[6] Ultralytics OBB documentation. https://docs.ultralytics.com/tasks/obb/. 본 파일럿은 DOTA 사전학습 YOLO11s-OBB 를 사용했다.