NeRF의 Outlier 제거와 오라클 함수 S

일반 정의 → 유형별 정의 → 적응형 S (RobustNeRF) → 베이킹 적용

참조: RobustNeRF (Sabour et al., CVPR 2023) § 3.1–3.2 | 정리일 2026-10-24

1. 문제: 왜 outlier를 제거해야 하는가

NeRF는 모든 학습 픽셀에 대해 L2 재구성 손실을 최소화한다.

$$\mathcal{L}_{\text{rgb}}(\theta) = \sum_i \sum_{\mathbf{r}} \left\| C(\mathbf{r};\theta) - C_i(\mathbf{r}) \right\|_2^2 \tag{3}$$

이 손실에는 두 가지 취약점이 있다.

- **시점 의존 항의 악용:** 일시적(transient) 객체가 찍힌 픽셀을 모델이 "이 방향에서 보면 이 색"이라는 view-dependent radiance로 암기해 버리는 지역 최적해가 존재한다.
- **L2(최소제곱)의 민감성:** 오차를 제곱으로 벌점화하므로 큰 잔차를 가진 소수 픽셀(outlier)이 해를 끌어당긴다.

결과적으로 사람, 차량, 하늘 같은 multi-view 일관성이 없는 픽셀이 ghosting, floater, 잘못된 형상으로 나타난다. 가장 직접적인 해법은 "이 픽셀은 학습에서 빼라"고 알려주는 외부 판정기를 두는 것이다.

2. 일반 정의: 오라클 함수 S

RobustNeRF는 이 외부 판정기를 **오라클** S로 추상화하고, 식 (3)을 다음으로 대체한다.

일반형 (RobustNeRF 식 (4))

$$\mathcal{L}_{\text{oracle}}^{\mathbf{r},i}(\theta) = S_i(\mathbf{r}) \cdot \left\| C(\mathbf{r};\theta) - C_i(\mathbf{r}) \right\|_2^2, \qquad S_i = S(C_i)$$

S를 사전학습된 의미 분할 네트워크 f_ϕ로 구현하면,

$$\hat{y}_i(\mathbf{r}) = \arg\max_k \ \text{softmax}\big(f_\phi(C_i)\big)_k(\mathbf{r}), \qquad S_i(\mathbf{r}) = 1 - \mathbb{1}\big[\hat{y}_i(\mathbf{r}) \in \mathcal{K}_{\text{dist}}\big]$$

- f_ϕ: 사전학습 분할 네트워크. ϕ는 **고정**(NeRF 학습 중 갱신하지 않음).
- $\mathcal{K}_{\text{dist}}$: distractor로 간주할 클래스 집합. **사람이 미리 정한다.**

부호 규약

본문은 "S가 outlier 여부를 지정한다"고 쓰지만, S는 손실에 곱해지므로 실제로는 $S_i(\mathbf{r}) = 1$이 inlier(유지), $S_i(\mathbf{r}) = 0$이 outlier(제외)여야 식이 성립한다. 아래 레퍼런스 중 URF의 하늘 마스크는 반대로 $S = 1$이 "하늘"을 뜻하므로 읽을 때 주의.

이 일반형에서 실제로 바꿀 수 있는 자유도는 세 가지다.

자유도	선택지
f_ϕ **(어떤 모델)**	DeepLab v3, DeepLabv3+, MediaPipe Selfie Segmentation 등
$\mathcal{K}_{\text{dist}}$ **(무엇을 제거)**	사람, 하늘, 비-전경(배경) 등
S**의 형태와 쓰임**	이미지 단위 0/1 / 픽셀 단위 0/1 / soft $[0,1]$; 손실 가중 또는 보조 손실

3. Outlier 유형에 따라 S가 달라진다

어떤 픽셀이 "outlier"인지는 장면과 과제에 따라 다르다. 따라서 S는 하나로 고정되지 않고, 제거 대상에 맞춰 다르게 설계되어 왔다.

Outlier 유형	왜 문제인가	S의 대응
움직이는 사람/객체	이미지마다 위치가 달라 multi-view 일관성 위반	해당 클래스 픽셀/이미지를 손실에서 제외
동적 객체 (클래스 기반)	차량·보행자 등 "움직일 수 있는" 클래스는 대개 실제로 움직임	movable 클래스 전체를 panoptic 분할로 마스킹
동적 객체 (일관성 기반)	클래스와 무관하게 여러 장에서 반복 관측되지 않음	SfM 매칭 빈도·색 잔차로 정적 영역을 찾고 SAM으로 확장
하늘	광선이 불투명 표면과 교차하지 않아 밀도 지도 신호가 약함	제외 대신 별도 모델(환경맵)로 넘기고 밀도를 0으로 유도
관심 대상 외 배경	단일 시점 데이터에서 전경/배경 분리 불가	soft 전경 확률로 NeRF 투명도 α를 지도

4. 레퍼런스별 S 구조

4.1 NeRF in the Wild (NeRF-W, Martin-Brualla et al., CVPR 2021)

제거 대상: 관광지 사진의 사람 등 일시적 가림(transient occluder), 저품질 이미지.
f_ϕ**:** DeepLab v3 (Chen et al., 2017) + 이미지 품질 평가 NIMA (Talebi & Milanfar, 2018).
S**의 형태:** 이미지 단위 필터. 데이터셋 구축 단계에서 가림이 심하거나 품질이 낮은 사진을 제외.

$$m_i(\mathbf{r}) = \mathbb{1}\big[\hat{y}_i^{\text{DLv3}}(\mathbf{r}) \in \mathcal{K}_{\text{transient}}\big], \qquad S_i = \mathbb{1}\Big[\tfrac{1}{|\Omega|}\textstyle\sum_{\mathbf{r}} m_i(\mathbf{r}) < \tau_{\text{occ}}\Big] \cdot \mathbb{1}\big[\text{NIMA}(C_i) > \tau_q\big]$$

학습 손실 자체에는 분할 마스크가 들어가지 않는다. 학습 중 transient 처리는 transient head와 불확실성 $\beta_i(\mathbf{r})$로 비지도 방식으로 한다. 임계값 $\tau_{\text{occ}}, \tau_q$와 정확한 클래스 목록은 본문에서 확인되지 않아 기호로 표기했다(보충자료 확인 필요). RobustNeRF의 "사람 픽셀 제거"라는 서술은 다소 단순화된 표현이다.

4.2 Urban Radiance Fields (URF, Rematas et al., CVPR 2022)

Street View 도시 장면. S를 **두 가지 목적**으로 사용한다.

(a) 사람 제거
f_ϕ**:** DeepLabv3+ (Chen et al., ECCV 2018, "Encoder-decoder with atrous separable convolution"). 가장 두드러진 이동 클래스인 사람 픽셀을 마스킹.

$$S_i^{\text{person}}(\mathbf{r}) = 1 - \mathbb{1}\big[\hat{y}_i^{\text{DLv3+}}(\mathbf{r}) = \texttt{person}\big], \qquad \mathcal{L}_{\text{rgb}} = \sum_i \mathbb{E}_{\mathbf{r}\sim I_i}\Big[S_i^{\text{person}}(\mathbf{r})\,\big\|C(\mathbf{r};\beta_i) - C_i^{gt}(\mathbf{r})\big\|_2^2\Big]$$

(b) 하늘 분리
f_ϕ**:** 사전학습 의미 분할 모델(해당 문장에 별도 인용 없음; (a)와 같은 모델로 보는 것이 자연스러움). 사전학습 데이터셋은 명시되지 않음.

$$S_i^{\text{sky}}(\mathbf{r}) = \mathbb{1}\big[\hat{y}_i(\mathbf{r}) = \texttt{sky}\big], \qquad \mathcal{L}_{\text{seg}}(\theta) = \mathbb{E}_{\mathbf{r}\sim I_i}\Big[S_i^{\text{sky}}(\mathbf{r}) \int_{t_n}^{t_f} w(t)^2\,dt\Big]$$

$$C(\mathbf{r};\beta_i) = \int_{t_n}^{t_f} w(t)\,\Gamma(\beta_i)\,\mathbf{c}(t)\,dt + \mathbf{c}_{\text{sky}}(\mathbf{d})$$

하늘 픽셀은 버려지지 않는다. 광선 위 밀도를 0으로 밀어 넣고, 색은 방향만 입력받는 환경맵 $\mathbf{c}_{\text{sky}}(\mathbf{d})$가 설명하도록 넘긴다. 여기서는 $S = 1$이 "하늘"이므로 일반형과 부호가 반대다.

4.3 LOLNeRF (Rebain et al., CVPR 2022)

제거 대상: 단일 시점 얼굴 데이터에서 얼굴(전경)이 아닌 영역.
f_ϕ**:** MediaPipe Selfie Segmentation, $\lambda_{\text{mask}} = 1.0$.
S**의 형태:** soft 전경 확률 $S_I(\mathbf{p}) \in [0,1]$. 손실에서 픽셀을 지우지 않고 NeRF 투명도를 지도하는 보조 손실로 사용.

$$\mathcal{L}_{\text{mask}} = \mathbb{E}_{k,\,\mathbf{p}\in I_k}\Big[\big(\alpha(\mathbf{p}\,|\,\mathbf{z}_k) - S_I(\mathbf{p})\big)^2\Big]$$

$$C(\mathbf{p}|\mathbf{z}) = \alpha(\mathbf{p}|\mathbf{z})\,C_{\text{NeRF}}(\mathbf{p}|\mathbf{z}) + \big(1-\alpha(\mathbf{p}|\mathbf{z})\big)\,C_{\text{bg}}(\mathbf{d}_{\mathbf{p}}|\mathbf{z})$$

얼굴 외 영역은 저용량 배경 모델 C_{bg}가 담당한다. RobustNeRF의 "얼굴 외 픽셀 무시"는 이 구조를 근사적으로 서술한 것이다.

4.4 Block-NeRF (Tancik et al., CVPR 2022) — 동적 객체, 클래스 기반

제거 대상: 도시 규모 주행 데이터(수개월에 걸쳐 수집)의 차량, 보행자 등 움직일 수 있는(movable) 객체. 서로 다른 시점·날짜에 찍힌 영상에서 장면 형상이 일관된다는 가정을 이 객체들이 깨기 때문이다.
f_ϕ**:** Panoptic-DeepLab (Cheng et al., CVPR 2020).
S**의 형태:** 픽셀 단위 0/1. 마스킹된 영역은 학습에서 무시된다.

$$S_i^{\text{mov}}(\mathbf{r}) = 1 - \mathbb{1}\big[\hat{y}_i^{\text{PDL}}(\mathbf{r}) \in \mathcal{K}_{\text{movable}}\big], \qquad \mathcal{L}_{\text{rgb}} = \sum_i \sum_{\mathbf{r}} S_i^{\text{mov}}(\mathbf{r})\,\big\|C(\mathbf{r};\theta) - C_i(\mathbf{r})\big\|_2^2$$

- 같은 분할 마스크를 **COLMAP 특징점 추출**에도 적용해, 포즈 추정 단계에서도 동적 객체를 배제한다. 즉 S가 NeRF 손실과 SfM 전처리 양쪽에 쓰인다.
- 실제로 정지해 있는 주차 차량도 movable 클래스이면 제거된다. "지금 움직이는가"가 아니라 "움직일 수 있는 클래스인가"로 판정하기 때문이다.

> 논문은 마스킹할 클래스 목록과 마스킹 손실 식을 명시하지 않는다(위 식은 "학습 중 무시"를 식 (4) 형태로 쓴 것). 저자들이 밝힌 한계로, 차량은 지워져도 **차량 그림자는 남는 경우가 많다**. 그림자는 분할 클래스가 아니기 때문에 클래스 기반 S로는 잡히지 않는다.

4.5 NeRF-HuGS (Chen et al., CVPR 2024) — 동적 객체, 일관성 기반

제거 대상: 클래스와 무관한 모든 transient/동적 객체. 사전 정의된 $\mathcal{K}_{\text{dist}}$ 없이, 여러 이미지에서 일관되게 관측되는가로 정적/동적을 판정한다.
f_ϕ**:** 휴리스틱 두 개 + Segment Anything (SAM). 잔차 계산용으로 짧게 학습한 Nerfacto(약 5k iteration)를 사용.
S**의 형태:** 픽셀 단위 0/1 정적 맵 M_i (1 = 정적, 0 = 동적).

(1) SfM 휴리스틱 — 정적 물체의 특징점은 많은 이미지에서 매칭된다.

$$\mathcal{X}_i = \Big\{\mathbf{x}_i^j \;\Big|\; \mathbf{x}_i^j \in \mathcal{F}_i,\;\; \tfrac{n_i^j}{N_{\mathcal{I}}} \geq T_{\text{SfM}}\Big\} \xrightarrow{\text{SAM (point prompt)}} H_i^{\text{SfM}}$$

n_i^j: 특징점 j가 이미지 집합에서 매칭된 횟수, $N_{\mathcal{I}}$: 전체 이미지 수.

(2) 색 잔차 휴리스틱 — 짧게 학습한 NeRF는 정적 영역부터 먼저 맞춘다.

$$\epsilon(\mathbf{r}) = \left\|\hat{C}(\mathbf{r}) - C(\mathbf{r})\right\|_2, \qquad H_i^{\mathrm{CR}} = \{\mathbf{r} \mid \mathcal{R}_i(\mathbf{r}) \le \mathrm{mean}(\mathcal{R}_i)\}, \qquad \hat{H}_i^{\mathrm{CR}} = \{\mathbf{r} \mid \mathcal{R}_i(\mathbf{r}) \le \mathrm{quantile}(\mathcal{R}_i, T_{\mathrm{CR}})\}$$

(3) 결합 및 SAM 분할

$$H_i = \left(H_i^{\mathrm{SfM}} \cup H_i^{\mathrm{CR}}\right) \cap \hat{H}_i^{\mathrm{CR}}, \qquad M_i = \bigcup_j m_i^j \quad \text{s.t.} \quad \frac{|m_i^j \cap H_i|}{|m_i^j|} \ge T_m$$

m_i^j: SAM이 만든 j번째 후보 마스크. 합집합으로 두 휴리스틱의 누락을 보완하고, 잔차 상한 $\hat{H}_i^{\mathrm{CR}}$과의 교집합으로 SfM/SAM이 잘못 정적으로 분류한 transient를 걸러낸다.

(4) NeRF 손실

$$\mathcal{L}(\mathbf{r}) = M_i(\mathbf{r}) \cdot \mathcal{L}_{\mathrm{recon}}\big(\hat{C}(\mathbf{r}), C(\mathbf{r})\big) \qquad (\mathcal{L}_{\mathrm{recon}}: \text{ MSE 또는 Charbonnier})$$

최종 형태가 RobustNeRF 식 (4)와 정확히 같다. 차이는 S를 만드는 방법뿐이다.

> 임계값 $T_{\mathrm{SfM}}, T_{\mathrm{CR}}, T_m$의 수치는 확인한 본문(arXiv v1)에서 찾지 못해 기호로 남겼다. HuGS는 RobustNeRF 이후(2024) 연구로, 잔차 기반 판정(RobustNeRF의 아이디어)과 분할 모델(오라클 아이디어)을 결합한 형태로 볼 수 있다.

5. 종합

레퍼런스	f_ϕ (모델)	제거 대상 $\mathcal{K}$	S 형태	사용 방식
NeRF-W	DeepLab v3 (+NIMA)	사람 등 transient, 저품질	이미지 단위 0/1	데이터셋 필터링 (학습 손실에는 미포함)
URF (a)	DeepLabv3+	person	픽셀 0/1	$\mathcal{L}_{\mathrm{rgb}}$ 가중 (식 (4)와 동일 구조)
URF (b)	사전학습 분할 모델	sky	픽셀 0/1 (부호 반대)	$\mathcal{L}_{\mathrm{seg}}$로 밀도 억제 + $\mathbf{c}_{\mathrm{sky}}$로 이관
LOLNeRF	MediaPipe Selfie Seg.	비-전경(배경)	soft $[0,1]$	$\mathcal{L}_{\mathrm{mask}}$로 α 지도 + C_{bg}
Block-NeRF	Panoptic-DeepLab	movable 객체 (차량, 보행자 등)	픽셀 0/1	학습에서 무시 + COLMAP 특징점에서도 제외
NeRF-HuGS	SfM 매칭 빈도 + 색 잔차 + SAM	클래스 무관 동적/transient	픽셀 0/1	식 (4)와 동일한 손실 가중

한계와 RobustNeRF로의 연결

NeRF-W, URF, LOLNeRF, Block-NeRF는 모두 $\mathcal{K}_{\mathrm{dist}}$, 즉 무엇이 distractor인지를 미리 정해야 한다. 분할 모델이 모르는 클래스이거나 장면마다 달라지는 임의의 distractor(풍선, 장난감, 가방, 그림자 등)에는 오라클을 만들 수 없다. Block-NeRF의 "그림자 잔존"이 그 대표적 증상이다.

$$\text{오라클 } S(C_i) \ \text{(의미 기반, 사전 정의)} \longrightarrow \text{잔차 기반 가중치 } \omega\big(\epsilon_i(\mathbf{r})\big) \ \text{(robust loss, 사전 정의 불필요)}$$

RobustNeRF는 이 문제를 풀기 위해 의미 분할 대신 **학습 중 잔차의 크기와 공간적 분포**로 outlier를 판정하는 robust loss를 제안한다. 이후 NeRF-HuGS는 이 잔차 신호에 multi-view 일관성(SfM)과 클래스 무관 분할(SAM)을 결합해, 사전 정의 없이 오라클 S를 스스로 구성하는 방향으로 확장했다.

6. RobustNeRF: 고정된 S에서 적응형 $S^{(t)}$로

6.1 무엇이 달라지는가

1–5절의 S는 모두 **학습 전에 한 번 계산되어 고정**된다. 입력은 원본 이미지 C_i뿐이고, NeRF가 무엇을 배웠는지와 무관하다.

$$\underbrace{S_i = S_\phi(C_i)}_{\text{고정 오라클: 이미지만 보고 판정}} \qquad \longrightarrow \qquad \underbrace{S_i^{(t)} = \omega\big(\epsilon_i^{(t-1)}\big)}_{\text{적응형: 현재 모델의 잔차를 보고 판정}}$$

RobustNeRF는 S를 **현재 모델의 재구성 잔차**로 매 반복 다시 계산한다. 사전학습 모델도, 클래스 목록 $\mathcal{K}_{\text{dist}}$도 필요 없다.

6.2 IRLS: 어떤 픽셀을 믿을지 반복해서 갱신

$$\mathcal{L}^{(t)}(\mathbf{r}) = \underbrace{\omega\big(\epsilon^{(t-1)}(\mathbf{r})\big)}_{\text{이전 모델로 계산한 신뢰도}} \cdot \underbrace{\big\|C(\mathbf{r};\theta^{(t)}) - C_i(\mathbf{r})\big\|_2^2}_{\text{현재 모델의 예측 오차}}, \qquad \epsilon^{(t-1)}(\mathbf{r}) = \big\|C(\mathbf{r};\theta^{(t-1)}) - C_i(\mathbf{r})\big\|_2 \tag{7}$$

반복 재가중 최소제곱(IRLS)의 순서는 다음과 같다: 현재 모델로 예측 → 실제 사진과 비교해 잔차 계산 → 잔차로 가중치 ω 결정 → ω를 고정하고 θ 갱신 → 반복. ω는 이번 업데이트에서 함께 미분하는 대상이 아니라 이전 추정으로 정해지는 값이다. 이 형태는 식 (4)에서 $S_i(\mathbf{r})$를 $\omega(\epsilon^{(t-1)}(\mathbf{r}))$로 바꾼 것과 같다.

다만 IRLS만으로는 **아직 덜 배운 디테일**과 **진짜 outlier**가 구분되지 않는다. 둘 다 잔차가 크기 때문이다. 핵심은 ω를 어떻게 정하느냐에 있다.

6.3 핵심 단서: outlier는 공간적으로 뭉쳐 있다

관측	학습 중 잔차의 공간적 모양
아직 배우지 못한 텍스처, 글자, 가는 무늬	작은 점이나 가는 선처럼 **국소적**. 주변은 대부분 잘 맞음
제거해야 할 방해물(사람, 차 등)	**넓고 연결된** 영역에 걸쳐 잔차가 큼

판단 원리: "이 픽셀은 오차가 크지만 주변은 잘 맞는다 ⇒ 아직 못 배운 디테일일 수 있다." 이는 항상 성립하는 법칙이 아니라 이 방법이 의도적으로 넣은 **귀납적 편향(inductive bias)**이다.

6.4 3단계 판정 (식 (8)–(10))

(1) 잔차 하위 50%를 임시 inlier로 선택 (trimmed LS)

$$\tilde{\omega}(\mathbf{r}) = \mathbb{1}\big[\epsilon(\mathbf{r}) \le \mathcal{T}_\epsilon\big], \qquad \mathcal{T}_\epsilon = \text{Median}_{\mathbf{r}}\{\epsilon(\mathbf{r})\} \tag{8}$$

여기서 멈추면 큰 잔차를 가진 실제 디테일도 함께 버려진다.

(2) 3×3 확산: 주변이 잘 맞으면 고립된 큰 잔차도 살린다

$$\mathcal{W}(\mathbf{r}) = \mathbb{1}\big[(\tilde{\omega} \circledast \mathcal{B}_{3\times3})(\mathbf{r}) \ge \mathcal{T}_\circledast\big], \qquad \mathcal{T}_\circledast = 0.5 \tag{9}$$

예: 중앙 픽셀만 0이고 주변 8개가 1이면 평균은 $8/9 \ge 0.5$이므로 중앙도 inlier로 복귀한다. 가는 무늬 위의 고립된 큰 잔차가 보호된다.

(3) 패치 단위 판정: 더 넓은 맥락

$$\omega(\mathcal{R}_8(\mathbf{r})) = \mathbb{1}\Big[\mathbb{E}_{\mathbf{s}\sim\mathcal{R}_{16}(\mathbf{r})}\big[\mathcal{W}(\mathbf{s})\big] \geq \mathcal{T}_{\mathcal{R}}\Big], \qquad \mathcal{T}_{\mathcal{R}} = 0.6 \tag{10}$$

학습 단위는 8×8 패치 $\mathcal{R}_8$, 판단에 참고하는 주변은 16×16 영역 $\mathcal{R}_{16}$이다. 학습 초기에는 디테일 주변도 덜 학습되어 있을 수 있어서 더 넓은 맥락이 필요하다. 중앙값은 초기 마스크의 기준일 뿐이므로, 최종적으로 "잔차 하위 50%만 학습한다"는 뜻은 아니다.

식 표기 주의

CVPR 게재본의 식 (9), (10)은 위처럼 평균의 임계값 비교만 있다. arXiv 렌더링에는 $\tilde{\omega}(\mathbf{r})\,|\,(\cdots) \geq \mathcal{T}$처럼 정의되지 않은 "|" 기호가 보이며, 이를 논리 OR로 읽으면 "자기 잔차가 작거나 주변이 좋으면 포함"이 된다. OR이 없으면 3×3 확산은 양방향 평활화가 되어, 잔차가 작아도 주변이 대부분 outlier인 픽셀(방해물 내부의 우연히 맞은 픽셀)은 제외된다.

6.5 기존 robust loss와의 차이

기존 robust loss (Huber, Geman–McClure 등)	RobustNeRF
각 픽셀의 잔차 크기만 보고 영향 조절 큰 잔차를 연속적으로 감쇠 ⇒ 디테일도 약하게 학습	잔차 크기 + 주변의 공간 구조를 함께 판단 최종적으로 0/1 마스크 ⇒ 포함된 디테일은 일반 L2로 제대로 학습
디테일과 outlier의 잔차가 비슷하면 구분 불가	작은 디테일 vs. 넓은 방해물의 **공간 스케일 차이**로 구분

요약

큰 잔차를 모두 약하게 배우지 말고, **공간적 맥락으로 배울 대상을 고른 뒤 그 대상은 제대로 배운다.** 텍스처와 글자 같은 국소적 고주파 디테일은 넓은 패치로 보면 주변이 맞으므로 살아남고, 넓게 뭉친 방해물은 패치 전체가 탈락한다. 즉 RobustNeRF의 S는 "**방해물의 공간 스케일 > 디테일의 공간 스케일**"이라는 가정 위에 서 있으며, 그 스케일을 정하는 것이 3×3, 8×8, 16×16이라는 필터 크기다.

7. 우리 베이킹(CityMesh)에의 적용 방안

설정. 항공 영상 $\{I_i\}$와 재구성된 도시 메쉬 $\mathcal{M}$이 주어지고, 텍스처 T를 미분 가능 렌더러 $\mathcal{R}$로 최적화한다고 두면 베이킹 손실은 식 (4)와 같은 꼴이 된다.

$$\mathcal{L}_{\text{bake}}(T) = \sum_i \sum_{\mathbf{r}} S_i(\mathbf{r}) \left\| \mathcal{R}(\mathcal{M}, T; \pi_i)(\mathbf{r}) - I_i(\mathbf{r}) \right\|_2^2$$

따라서 1–6절의 S 설계를 그대로 가져올 수 있다. 여기서 주된 이동 객체는 **차량**이다.

7.1 방안 1: RobustNeRF 방식 차용 + 차량 크기에 맞춘 필터

RobustNeRF의 3×3, 8×8, 16×16은 NeRF 벤치마크 해상도에서 "사람/물체 크기 > 디테일 크기"가 되도록 정한 값이다. 우리는 방해물이 대부분 차량이므로, **필터 크기를 차량의 화면상 크기에 맞추는 것**이 자연스럽다. 차량 길이를 $L_{\text{car}} \approx 4.5\,\text{m}$, 카메라 초점거리를 f(픽셀), 깊이를 D라 하면,

$$\text{GSD} = \frac{D}{f}\ \ [\text{m/px}], \qquad k_{\text{car}} = \left\lceil \frac{L_{\text{car}}}{\text{GSD}} \right\rceil = \left\lceil \frac{L_{\text{car}}\, f}{D} \right\rceil\ \ [\text{px}]$$

$$\mathcal{R}_8 \;\to\; \mathcal{R}_{k/2}, \qquad \mathcal{R}_{16} \;\to\; \mathcal{R}_k, \qquad k \approx k_{\text{car}}$$

- 판단 영역 $\mathcal{R}_k$가 차량 한 대를 덮을 정도면, 차량 내부 패치는 주변 대부분이 outlier라 탈락하고, 도로 표시선·간판 글자처럼 가늘고 국소적인 고잔차는 살아남는다.
- 주의: 차선, 횡단보도처럼 차량보다 넓게 뻗은 고잔차 텍스처는 같은 기준으로 잘못 탈락할 수 있다. 학습 초기의 잔차 분포를 확인해 $\mathcal{T}_{\mathcal{R}}$를 조정해야 한다.

7.2 방안 2: S를 "차량 판별기"로 정의 (휴리스틱)

Block-NeRF처럼 검출/분할 모델로 차량을 직접 지우는 방식이다.

$$S_i(\mathbf{r}) = 1 - \mathbb{1}\big[\mathbf{r} \in \text{MaskRCNN}_{\text{car}}(I_i)\big]$$

구현은 간단하지만 클래스 기반 오라클의 한계를 그대로 가진다.

- **주차 차량 문제:** 정지 차량은 여러 장에서 일관되게 관측되므로 정적 장면의 일부일 수 있는데, 클래스 기반 S는 모두 지운다. 지운 자리를 채울 다른 시점 텍스처가 없으면 구멍이 생긴다.
- **그림자, 버스, 트럭 등** 클래스 밖 방해물은 놓친다(Block-NeRF의 그림자 잔존과 같은 문제).
- 참고 사례: Yang et al. (2021)은 UAV 사선 영상 메쉬에서 Mask R-CNN 검출 후, 메쉬 삼각형을 다른 시점으로 투영해 차량이 몇 시점에서 같은 자리에 있는지로 이동/단기 정차/정지를 나눈다(7.3 (b) 참고). 순수 판별기보다 multi-view 기하를 함께 쓰는 쪽이 낫다는 근거다.

7.3 방안 3 (컨트리뷰션 후보): geometry-aware S

NeRF 계열의 S는 모두 **RGB(또는 RGB에서 나온 잔차·특징)**만으로 판정한다. 기하가 바로 추정 대상이라 믿을 수 없기 때문이다. 반면 우리는 **메쉬 $\mathcal{M}$을 이미 갖고 있고**, 각 시점의 렌더 깊이 $\hat{D}_i(\mathbf{r})$, 법선, 지면 대비 높이, 시점 간 픽셀 대응을 기하적으로 얻을 수 있다. 이 정보를 S에 넣는 것이 우리 설정에서만 가능한 확장이다.

관련 레퍼런스

레퍼런스	기하 단서	판정 방식
(a) Waechter et al., ECCV 2014 (메쉬 텍스처링)	메쉬 면 단위 multi-view 대응	면 F를 보는 각 시점의 평균색 $\mathbf{c}_i$에 가우시안을 맞추고, 값이 6×10^{-3} 미만인 시점을 반복 제거(최대 10회). 남은 시점만 텍스처 후보로 사용. 메쉬로 재구성되지 않은 보행자 같은 가림을 거르기 위한 장치
(b) Yang et al., Remote Sensing 2021 (UAV 사선 영상)	메쉬 삼각형을 다른 시점에 투영	차량 마스크 영역이 다른 시점에서도 차량으로 덮인 비율 n_1/n_k: < 0.05 이동, < 0.85 단기 정차, 그 외는 색 히스토그램 일치율 ≥ 0.8이면 정지. 이동 차량은 텍스처만 지우고, 단기 정차는 텍스처를 지우고 메쉬를 평탄화
(c) Removert (Kim & Kim, IROS 2020)	깊이(range) 가시성	지도 점이 현재 관측보다 앞에 있어 관측 광선을 가리면 동적으로 판정. 여러 해상도의 range image로 제거한 뒤 정적 점을 복원(revert)
(d) ERASOR (Lim et al., RA-L 2021)	지면 대비 높이	동적 객체는 대부분 지면에 닿아 있다는 가정. 영역별 높이 범위 Δh의 지도/관측 비가 < 0.2이면 동적 후보, 지면 평면 적합 후 지면이 아닌 점 제거

제안 formulation (후보, 검증 전)

(i) 깊이로 필터 크기를 픽셀마다 정한다. 7.1의 D에 메쉬 렌더 깊이를 넣으면 사선 영상에서도 위치마다 차량의 화면 크기가 달라지는 것을 반영할 수 있다.

$$k_i(\mathbf{r}) = \left\lceil \frac{L_{\text{car}}\, f}{\hat{D}_i(\mathbf{r})} \right\rceil \qquad \Rightarrow \qquad \omega_i(\mathbf{r}) = \mathbb{1}\Big[\mathbb{E}_{\mathbf{s}\sim\mathcal{R}_{k_i(\mathbf{r})}(\mathbf{r})}\big[\mathcal{W}(\mathbf{s})\big] \geq \mathcal{T}_{\mathcal{R}}\Big]$$

(ii) 잔차를 메쉬 표면으로 올려 시점 간 일관성을 본다 (Waechter, Yang 방식의 일반화). 픽셀 $\mathbf{r}$이 맞는 면을 $F(\mathbf{r})$라 하면,

$$\bar{\epsilon}_F = \text{Median}_{j\in\mathcal{V}(F)}\ \epsilon_j(F), \qquad \rho_i(\mathbf{r}) = \frac{\big|\{j \in \mathcal{V}(F(\mathbf{r})) :\ \epsilon_j(F(\mathbf{r})) > \mathcal{T}_\epsilon\}\big|}{|\mathcal{V}(F(\mathbf{r}))|}$$

$\mathcal{V}(F)$는 면 F를 보는 시점 집합이다. 잔차가 모든 시점에서 크면($\rho \approx 1$) 아직 못 배운 정적 디테일이고, 일부 시점에서만 크면(ρ 작음) 그 시점에만 있던 차량일 가능성이 높다. 2D 공간 스케일 대신 **3D 시점 일관성**으로 디테일과 방해물을 가르는 셈이다.

(iii) 지면 근접 높이 prior (ERASOR 방식). 메쉬에서 면의 지면 대비 높이 $h(F)$를 구하면 차량이 놓일 수 있는 높이 범위 $[0, h_{\text{car}}](h_{\text{car}} \approx 2\,\text{m})$ 밖의 고잔차는 차량이 아니라 디테일로 본다.

(iv) 결합.

$$S_i(\mathbf{r}) = 1 - \underbrace{\big(1-\omega_i(\mathbf{r})\big)}_{\text{(i) 차량 크기 패치 outlier}} \cdot \underbrace{\mathbb{1}\big[\rho_i(\mathbf{r}) < \mathcal{T}_\rho\big]}_{\text{(ii) 일부 시점에만 존재}} \cdot \underbrace{\mathbb{1}\big[0 \leq h(F(\mathbf{r})) \leq h_{\text{car}}\big]}_{\text{(iii) 지면 근처}}$$

세 조건을 모두 만족할 때만 제외한다. 각 항은 독립적으로 끄고 켤 수 있으므로 ablation이 쉽다.

가정과 확인할 점

- 메쉬가 차량을 포함하지 않는다고 가정했다. 생성형 메쉬에 차량 형상이 들어가 있으면, 차량 자리의 렌더 깊이가 도로보다 얕아지므로 (c)처럼 깊이 차이를 직접 단서로 쓸 수 있다.
- 시점 수가 적은(few-shot) 설정에서는 $|\mathcal{V}(F)|$가 작아 ρ가 불안정하다. Waechter 방식처럼 최소 시점 수(예: 4) 미만이면 (ii)를 끄는 규칙이 필요하다.
- (ii)의 시점 간 비교는 노출·색 보정 차이에 민감하다. URF의 시점별 affine 색 보정을 먼저 적용하는 것이 안전하다.
- 위 formulation은 레퍼런스들의 아이디어를 우리 설정에 맞춰 조합한 **제안**이며 실험으로 검증되지 않았다.

참고문헌

[1] S. Sabour et al., "RobustNeRF: Ignoring Distractors with Robust Losses," CVPR 2023.

[2] R. Martin-Brualla et al., "NeRF in the Wild: Neural Radiance Fields for Unconstrained Photo Collections," CVPR 2021.

[3] K. Rematas et al., "Urban Radiance Fields," CVPR 2022 (arXiv:2111.14643).

[4] D. Rebain et al., "LOLNeRF: Learn from One Look," CVPR 2022 (arXiv:2111.09996).

[5] L.-C. Chen et al., "Rethinking Atrous Convolution for Semantic Image Segmentation" (DeepLab v3), arXiv:1706.05587, 2017.

[6] L.-C. Chen et al., "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation" (DeepLabv3+), ECCV 2018.

[7] H. Talebi, P. Milanfar, "NIMA: Neural Image Assessment," IEEE TIP 2018.

[8] M. Tancik et al., "Block-NeRF: Scalable Large Scene Neural View Synthesis," CVPR 2022 (arXiv:2202.05263).

[9] B. Cheng et al., "Panoptic-DeepLab: A Simple, Strong, and Fast Baseline for Bottom-Up Panoptic Segmentation," CVPR 2020.

[10] J. Chen et al., "NeRF-HuGS: Improved Neural Radiance Fields in Non-static Scenes Using Heuristics-Guided Segmentation," CVPR 2024 (arXiv:2403.17537).

[11] A. Kirillov et al., “Segment Anything,” ICCV 2023.

[12] M. Waechter, N. Moehrle, M. Goesele, “Let There Be Color! Large-Scale Texturing of 3D Reconstructions,” ECCV 2014.

[13] C. Yang, F. Zhang, Y. Gao, Z. Mao, L. Li, X. Huang, “Moving Car Recognition and Removal for 3D Urban Modelling Using Oblique Images,” Remote Sensing 13(17):3458, 2021.

[14] G. Kim, A. Kim, “Remove, then Revert: Static Point Cloud Map Construction using Multiresolution Range Images,” IROS 2020.

[15] H. Lim, S. Hwang, H. Myung, “ERASOR: Egocentric Ratio of Pseudo Occupancy-based Dynamic Object Removal for Static 3D Point Cloud Map Building,” IEEE RA-L 2021.